

MTSC2025

中国互联网测试开发大会

TESTING SUMMIT CONFERENCE CHINA 2025

上海站

质效革新·智领未来

2025/7/12 | 上海喜来登由由大酒店 主办方: TesterHome

MTSC2025 中国互联网测试开发大会 上海站
TESTING SUMMIT CONFERENCE CHINA 2025

华为ADC Code Agent评测实践

陈永健

质效革新·智领未来

主办方: TesterHome

陈永健

华为 GTS平台测试总工

19年华为运营商领域软件测试经验，6级专家，目前主要负责华为运营商软件数智化转型与AI云原生平台开发测试，长期专注测试技术发展，在AI大模型/Agent评测、混沌工程（鲁棒性测试）、生态兼容性测试、自动化测试、性能与仿真测试等领域有深入探索，支撑和保障全球300+运营商客户稳定运营。

目录

CONTENTS

1. 华为 ADC CodeAgent平台介绍
2. CodeAgent 评测挑战与实践总体思路
3. 评测标准与体验一致性优化
4. 构建领域智码评测系统
5. 业务效果与下一步展望

01

华为 ADC CodeAgent平台介绍

从低码到智码，华为ADC应用开发平台

ADC（Agent Development Center）是一个面向业务开发者低代码、安全可信的**全场景**开发平台，具备完整的**资产生命周期管理**工具链，提供以**业务资产**为核心的**高效复用**的新开发模式。

支撑多场景基于低码编排快速实现业务应用

智能运维

智慧运营

网络集成


5G
行业应用

企业场景生态伙伴低
码开发应用

...

ADC：一体化编排应用开发平台 可信安全

低门槛/高效率



- 支持以**图形化**、类自然语言方式构造应用服务
- 开放流程、界面、数据、AI等多种编排能力，**所见即所得**

可信安全



- 提供APP质量评估系统，保障APP高质量交付
- 提供端到端可信工具链，轻松构建可信APP资产

生态开放



- 支持多协议、多引擎，随心构建、极速集成扩展
- API集成图形编排，集成资产全面复用共享


学习资料多，高能耗集中
开发者求助开销大



问题：门槛和Top高能耗点有进一步改进空间

□ 技术门槛不够低

- 精确获取资料难：分散在开发文档、培训教程以及社区问答
- 脚本开发门槛高：需一定的编程基础，且有大量领域API知识
- 体验设计专业强：页面布局及用户视觉体验有较强的专业性



□ 页面编排不够易用


- 组件的配置复杂度高，操作繁琐：如Echart类组件配置属性 **100左右**，无法统一修改多个UI组件属性。
- 非必要使用脚本实现（约 **10%+**）：如通过JS渲染ADC已支持的NoCodeUI组件；

□ 脚本编排存在优化空间

- 代码臃肿导致重复率高（约 **30%**）：公共函数未封装，随意Copy；
- Dashboard类页面开发效率低：Dashboard页面开发需大量手工的JS脚本开发，单个页面编排需要 **7天**；
- 低质脚本影响大：**90%+**性能问题由低质量JS和TQL导致

□ 流程编排节点耗时大

- 流程节点选择困难：大多流程节点涉及服务调用，开发者对可调用的服务并不熟悉，卡断明显；
- 节点参数填写复杂：流程节点中需要配置的参数包括触发器、校验器、表达式、级联输入输出等，填写复杂；



华为 ADC Code Agent 完整开发旅程的智码全景

智能

多模态输入


Copilot辅助生成

辅助代码解释

智能问答

测试用例自动生成
智能化测试

智能检测和自动优化




智能

需求澄清器
SA需求即应用

智能续写/推荐
存量转需求澄清


存量修改和关联修改
智能发现问题和自动优化

完整开发旅程中，构建智码核心竞争力，还存在多个环节智能提效缺失或不足，同时已有能力还需要进一步做深、做广。



02

CodeAgent 评测挑战与实践总体思路



随着模型效果的显著提升，模型评测的重要性日益凸显。代码评测也是大模型应用评测一个很重要的垂类领域，如何客观的、系统性的、自动化的量化评测AIGC生成代码的质量是一件极具挑战的事情。

什么是好的代码？


- 功能正确性
- 符合编码规范
- 安全合规
- 高性能
- 高可靠性
- 高可维护性
- 代码可读性
-




代码评测挑战

- 生成的代码片段不可执行，无法通过测试用例执行评估！
- 关于代码评测指标多种多样，如何选取适合业务实际场景的评测指标？
- 多语言代码如何评测，是否能统一评测框架？






评测集构建思路：以业务能力评测为主，兼顾评测通用能力对业务能力的基础影响,同时具备快速开展全量评估能力（自动化）应对不同版本不同模型下测试结果对比



➤被测对象业务逻辑分析




➤评测标准和评估方式

- ✓ 评测标准
- 1、文档规范:
- 语法正确性: 没有基础语法问题, 没有错别字、拼写错误等
 - 文档可读性: 文档结构层次清晰, 语言表达通俗易懂, 用词精准, 图表紧密合, 无长篇大论的文字描述。
 - 格式规范性: 使用正确的文档模板, 包括文档命名、封面、目录、页眉页脚等
- 2、内容质量:
- 完整性: 需求文档内容关键元素完整, 场景覆盖完整, 功能/非功能需求表述完整
 - 明确性: 无歧义表述, 避免使用“可能”“尽量”等模糊词汇; 需求分析过程按照逻辑顺序组织; 指标量化, 对异常场景处理有明确方案; 专业术语有明确定义
 - 一致性: 业务需求、用户需求、系统需求之间映射一致性; 功能与非功能之间各条目相互支持, 不存在逻辑上的矛盾; 文档中使用的术语和定义保持一致性。
- 3、可交付性:
- 技术可行性: 需求设计方案具备可落地性, 包括时间、成本等
 - 可验证性: 有明确的验收标准, 包括量化的性能指标、功能边界、系统规格约束
- ✓ 评估方式:
- 1、从文档规范性、内容质量、可交付性三个维度, 对需求文档的章节内容质量和整体质量进行评估打分;
- 2、采用扣分制 (满分100), 细分每个评测维度的指标项、权重和扣分原则。
- 3、汇总每个维度加权扣分值计算总得分, 并根据得分划分等级 (优秀/良好/不合格)

场景库: 知识导入、知识清洗、领域知识管理、场景知识召回

➤被测对象业务逻辑分析



➤评测集构建

✓ 评测集构建维度来源


- 1、基于语料知识库构建：语料加工/泛化的问题，效率高
- 2、基于业务特性进行全功能点覆盖构建：功能树
- 3、不同用户角色进行用户场景覆盖：初学者、资产开发者、资产管理员、运维人员等构建不同用户场景、不同难易程度的问题
- 4、真实用户反馈：收集真实场景下系统表现的数据，了解用户需求和期望

✓ 结果评估

- 1、评估方式：
 - 1) 参考答案 VS 实际结果，语义相似度
 - 2) 5分制评估， $P = \text{正确性} \times 0.4 + \text{相关性} \times 0.3 + \text{完整性} \times 0.2 + \text{流畅性} \times 0.1$ ； $P \geq 3.5$ 视为准确
- 2、关键因素：“参考答案”的制定，主客观结合

➤ 被测对象业务逻辑分析

NL2Model、Excel2Model：构建Prompt模板，根据自然语言生成Mysql建表语句，对接大模型生成中间DSL，解析中间DSL，转换为模型结构的JSON，最后进行生成结果修正、添加系统字段、完善约束信息等后置处理。



```
ADC2Copilot / code / mk
nl2property.prompt 修改 历史 对比 3.1 KB 976 于 2024-05-14 11:06:59 全屏 复制
1 *** MySQL 生成***
2 你是MySQL建模专家，需要根据提供的建表语句和问题，生成alter语句对表进行修改
3
4 建表语句如下：
5 ...
6 {table_info}
7 ...
8
9 生成的Alter语句需要满足以下条件：
10 1.注意列名，必须是英文，且不要生成名称为id、keycode、change_time和active的列。
11 2.Alter语句需要包括列的COMMENT作为列的显示名称，并确保COMMENT使用(Language)。
12
13 请注意问题中描述的列类型。除了MySQL支持的列类型外，还需要支持以下类型：
14 #listfile: 文件和文件列表类型，按照listfile(文件类型,文件大小,文件数量,文件重传)格式返回
15 #sequence: 序列类型，按照sequence(sequence类型,sequence format)格式返回，支持AUTO、DAIS（时间和日期序列）、UUID、DUTS（分布式时间序列）等类型的序列
16 #password: 密码字段，按照password(AES/SHA256)格式返回，支持AES和SHA256加密
17 #enum: 枚举类型，支持指定枚举值。枚举值需要翻译成英文。
18 #usergroup: 用户类型或用户组类型，按照usergroup(single, user, group)格式返回，支持指定single或者many，支持指定user/group/user, group
19 #timestamp: 时间戳，按照timestamp(Second/Millisecond)格式返回，支持毫秒和秒，如果没有指定，默认是毫秒。
20 #reference: 引用类型，按照reference('/xxx/xxx/xxx')格式返回，引用参数类似'/xxx/xxx/xx'格式。除非指定属性类型，否则不要将属性生成引用类型。
21 #decimal: 小数类型，按照decimal(有效位数,小数位数,最大值,最小值)格式返回，有效位数默认30，小数位数默认10，最大值最小值如果不指定，则默认为0
22 指定的内容存在于列的argument参数中。
23
24 以JSON格式响应，格式如下：
25 {
26   "sqlList": ["ALTER TABLE ..."]
27 }
28
29 示例：
30 问题：增加考勤状态属性，并设置为主键，删除出勤时间属性，修改员工id为uuid的序列类型，并设置为主键，修改员工年龄为员工工龄，并修改类型为枚举类型，取消部门属性的默认值。
31 回答：
```

关键要素：

- 1、输入内容：自然语言、Excel
- 2、Prompt：nl2model.prompt、excel2model.prompt、nl2property.prompt
- 3、大模型生成mysql建表语句：生成内容的相关性、语法正确性、需求匹配度（字段名称、类型）、数据类型&约束合理性、业务逻辑一致性（例如：订单表中要有订单状态字段）
- 4、大模型生成中间DSL：转换的完整性、正确性、可执行
- 5、adc-model后处理：模型的Json结构等

➤ 评测集构建

✓ 测试集


- 1、输入内容：自然语言、Excel；指定模型字段/约束、不指定模型字段/约束
- 2、功能特性：基于模型元数据的JSON结构进行，模型类型、模型字段类型、模型约束等功能点遍历覆盖
- 3、业务场景：设备管理、考勤管理、订单等模型覆盖
- 4、真实用户反馈：收集真实场景下系统表现的数据，了解用户需求和期望

✓ 结果评估

- 1、评估方式：
 - 1) 参考答案 VS 实际结果
 - 2) 5分制评估， $P = \text{正确性} \times 0.4 + \text{完整性} \times 0.3 + \text{可执行性} \times 0.2 + \text{相关性} \times 0.1$ ； $P \geq 3.5$ 视为准确
- 2、扩展评估：主键/索引、字段说明、用途描述等扩展性
- 3、关键因素：“参考答案”，尤其是模型元数据约束制定，偏主观

➤ 被测对象业务逻辑分析

NL2TQL: 根据自然语言, 从向量库进行模型信息检索, 基于Prompt模板对接大模型生成Mysql语句, 使用SQL2TQL转换成TQL语句, 然后进行函数转换、变量转换、语法修正等一系列后处理。



关键要素:

- 1、输入内容: 自然语言
- 2、**Prompt**: tql_generation_zh_CN.prompt、 tql_explain_zh_CN.prompt、 tql_optimize_zh_CN.prompt
- 3、向量库检索: 检索结果相关性
- 4、**大模型生成Mysql语句**: 生成内容的相关性、语法正确性、需求理解和匹配度、业务逻辑正确性、安全性、性能/效率
- 5、SQL2TQL、adc-model后处理: 后处理的TQL可执行、语法正确、模型/变量、安全性、查询性能等

➤ 评测集构建

✓ 测试集


- 1、输入内容: 自然语言
- 2、功能特性: 基于TQL支持语法结构, 进行单表/多表查询、带TQL函数、带condition、别名等; (基于大模型泛化的查询语句补充覆盖)
- 3、业务场景: 告警、工单等数据查询TQL
- 4、真实用户反馈: 收集真实场景下系统表现的数据, 了解用户需求和期望

✓ 结果评估

- 1、评估方式:
 - 1) 参考答案 VS 实际结果
 - 2) 5分制评估, $P = \text{正确性} \times 0.4 + \text{完整性} \times 0.3 + \text{可执行性} \times 0.2 + \text{相关性} \times 0.1$; $P \geq 3.5$ 视为准确
- 2、扩展评估: 结构清晰可读
- 3、关键因素: “参考答案”

➤ 被测对象业务逻辑分析

根据自然语言，调用大模型做步骤拆解、信息提取，从向量库匹配私域知识，动态构建Prompt，然后调用大模型生成代码，adc-studio-xxx进行代码语法检查、纠错等后处理。



关键要素:

- 1、输入内容：自然语言
- 2、Prompt：动态构建
- 3、**向量库检索**：检索私域知识的相关性、正确性
- 4、**大模型生成代码**：生成内容的相关性、完整性、语法正确性、需求理解和匹配度、业务逻辑正确性、安全性
- 5、adc-studio-xxx：后处理后的代码语法正确、可执行、执行效率等

➤ 评测集构建




✓ 测试集

- 1、输入内容：自然语言
- 2、功能特性：平台提供的 API、SDK接口全覆盖代码片段生成；
- 3、业务场景：设备管理、告警派单、费用报销、请假流程、考勤系统等的服务JS、页面JS等代码生成场景（来源：业务资产包）
- 4、真实用户反馈：收集真实场景下系统表现的数据，了解用户需求和期望

✓ 结果评估


- 1、评估方式：
 - 1) 代码静态检查（需求、逻辑、合规）， $P = \text{需求} * 0.5 + \text{逻辑} * 0.3 + \text{合规} * 0.2$
 - 3) 代码可执行：基于任务pass@k k=10；通过率=通过的用例数/K*用例数
- 2、扩展评估：结构清晰可读、代码注释、执行效率
- 3、关键因素：可执行性评估，依赖 代码上下文补齐 + 代码可执行性评估框架（目前不具备）

➤ 被测对象业务逻辑分析



关键要素：

- 1、输入内容：自然语言
- 2、Prompt：动态构建
- 3、大模型生成DSL：生成内容的相关性、完整性、语法正确性、需求理解和匹配度、业务逻辑正确性
- 4、adc-studio-ui：根据DSL设置组件属性并渲染页面组件效果



➤ 测试集评测

✓ 测评集





- 1、输入内容：自然语言
- 2、功能特性：1) 组件粒度：组件属性、组件事件、组件数据源遍历覆盖；2) 页面粒度：表单/表格、基于大屏模板推荐生成大屏页面
- 3、业务场景：大屏监控、报表分析等场景下的页面、页面组件
- 4、真实用户反馈：收集真实场景下系统表现的数据，了解用户需求和期望

✓ 结果评估

- 1、评估方式：
 - 1) 参考答案 VS 实际结果
 - 2) 5分制评估， $P = \text{正确性} \times 0.4 + \text{完整性} \times 0.3 + \text{可执行性} \times 0.2 + \text{相关性} \times 0.1$ ； $P \geq 3.5$ 视为准确
- 2、扩展评估：生成效率
- 3、关键因素：“参考答案”

➤ 被测对象业务逻辑分析

基于自然语言通过gpt转化成BPMN2.0 XML，adc-bpm支持基于bpmn创建基础流程，生成流程相关的编排元素，包括：模型、服务、页面。



关键要素：

- 1、输入内容：自然语言
- 2、**Prompt**： process-create.prompt、 process-excel-info.prompt 、 process-user-task-form.prompt
- 3、**大模型生成BPMN2.0 XML**：生成内容的相关性、完整性、语法正确性、需求理解和匹配度、业务逻辑正确性
- 4、**adc-bpm基于BPMN创建基础流程**：调用各个编排元素进行元数据转换、基础模板、创建的流程**可执行**
- 5、汇总后的结果展示：新增/修改/删除功能等

➤ 测试集评测

✓ 测试集

- 1、输入内容：自然语言、Excel；
- 2、功能特性：基于流程元数据的 bpmn_model、 basic_info进行遍历覆盖，基于流程支持事件、活动、网关等覆盖
- 3、业务场景：变更管理、告警故障管理、问题单处理等典型流程
- 4、真实用户反馈：收集真实场景下系统表现的数据，了解用户需求和期望

✓ 结果评估

- 1、评估方式：
 - 1) 参考答案 VS 实际结果
 - 2) 5分制评估， $P = \text{正确性} * 0.4 + \text{完整性} * 0.3 + \text{可执行性} * 0.2 + \text{相关性} * 0.1$ ； $P \geq 3.5$ 视为准确
- 2、扩展评估：简洁性（避免过度复杂化、合理分层为子流程等）
- 3、关键因素：“参考答案”


03


评测标准与体验一致性优化

ADC Code Agent评测资产库




好的评测标准是评测结果与用户体验一致





分析用户侧反馈数据，建立测评标准飞轮



注：现网数据获取需脱敏并征得用户授权许可

04

构建Code Agent评测系统



- ◆评测集管理：
- 项目测试数据隔离

通用/安全评测集资产共建共享，平台已沉淀3W+公共评测集
- ◆辅助测试设计：
- 通过关键字组合快速生成评测集用例。

通过文档提取QA，快速生成评测集用例。

通过改写泛化&扰动因子，快速泛化鲁棒性评测集。
- ◆评测任务：
- 准确性/安全性/鲁棒性/一致性/性能任务评测
- ◆裁判评分模型：
- 知识问答裁判模型（正确性+相关性+完整性）；

Python/JS/TQL代码生成、解释、检视裁判模型；

内容安全合规裁判模型；
- ◆问题标注：
- 支持人工标注结果，自动继承人工评价

标注结果可作为负向反馈持续迭代优化评分模型
- ◆评测报告：
- 版本级报告导出

任务级报告导出

历史版本报告比对导出


评测系统关键技术点：裁判模型

人工确认




评测系统关键技术点：代码生成Agent（AI4Script） 评测技术方案

通过主观和客观相结合的方式对代码生成类Agent质量进行评测。主观评测主要是应用LLM+CoT按照评测规范指标进行检查打分、客观评测是使用算法对比Agent生成代码和参考代码差异进行评测。



评测系统关键技术点：基于代码生成价值的量化评测算法（RoES）

RoES（Rouge-L And Edite Similarity）是在ROUGE-L算法和Levenshtein Distance算法基础上的自定义算法。



1. 降噪处理

- 对参考答案和生成结果进行降噪处理，删除代码中的注释、常量字符串、忽略注释换行符/空行/各类特殊字符、连续字符串、拼接纠错、命名实体抽取等。

2. 数据预处理

- 对参考答案和模型生成结果进行数据归一化预处理，包括：
 - 1) 统一同一方法和参数名引用
 - 2) 统一同一方法的同类型变量声明

3. 算法优化


- 词粒度：Levenshtein Distance算法采用的是字符粒度计算编辑距离，优化为单词/变量粒度，统计模型生成代码到参考答案的最小编辑距离（插入、删除、替换操作的次数）。
- 距离计算优化：对于整行代码删除操作，不区分删除的单词的数量，编辑距离计为1次；忽略对空格/空行等编辑次数；连续删除的行或单词，编辑距离计为1次。

4. 分值转换

- 相似度取值[0, 1]，转换为5分制
- $$\text{Score} = (f(\text{Rouge-L}) * w1 + f(\text{ES}) * w2) * 5$$

评测系统关键技术点：基于大模型+CoT代码生成主观评测Agent

使用大模型作为裁判来评估CodeAgent在各种场景下的表现，用来弥补各种基准测试以及基于规则算法的测试不足，同时也可以作为一种接近人类偏好的评价指标；相比人工评测更高效、更稳定，且具备可扩展性、可解释性。



✓ 评测标准：

- 1) 输出代码结构正确性，是否遵从Prompt输出格式要求等；
- 2) API及API参数选择正确性；
- 3) 生成代码是否能够解决用户问题，代码逻辑是否正确；
- 4) 生成的CoT推理过程是否正确，包括逻辑是否正确，是否有错误、是否有冗余推理信息等。

✓ 提高裁判模型评估准确性方法：

- 1) 测评集的参考答案标注质量；
- 2) 少样本示例：提供样例帮助裁判模型更好的推理；
- 3) CoT：要求模型给出评分的推理过程，帮助优化改进。

评测系统关键技术点：代码多指标的综合评测标准

规则集：用于做代码检查的规则组成的集合；可根据不同编程语言、编码规范、质量要求等因素来制定。



代码规范检查引擎

Python	JavaScript
CodeMars	CodeMars
Cmetrics	Cmetrics
Fortify	Fortify
Pylint	SecBrella
SecBrella	
Flake8	

+ SaaSAQM 资产规范扫描服务 + 平台内置SDK 扫描API

代码规范满足度三种计算公式

$$P1 = \frac{\text{满足规范}_1\text{测试集数量} + \text{满足规范}_2\text{测试集数量} + \dots + \text{满足规范}_N\text{测试集数量}}{\text{规范}_N\text{条} * \text{测试集}_M} * 100\%$$

$$P2 = \frac{\text{规范扫描后 (全满足测评集数量)}}{\text{测评集总数}_M} * 100\% \text{ (严格指标)}$$


$$P3 = \frac{\text{测试集}_1\text{得分} + \text{测试集}_2\text{得分} + \dots + \text{测试集}_N\text{得分}}{\text{测评集总数}_M} \text{ (分)}$$

(其中测试集M得分 = 100 - 不满足规则项扣分。扣分规则：通用类/ 安全类/低码类问题按照：致命 -10分，严重 -3分，提示 -0.1分)



提高生成代码的可读性、可维护性、可移植性、安全性、可靠性、高效性、编译正确性

评测系统关键技术点：测试集构建与测试集泛化

➤ 测试集构建：业务场景驱动，覆盖不同质量属性维度用户活动，自建+回流



➤ 测试集泛化：种子测试集，基于因子库+LLM进行变异泛化



05

业务评测效果与下一步展望

特性分类	辅助编排能力	测试集数量	自动化工具	效率提升
知识问答	知识问答/技术问答	XXXX	可全量裁判打分	1、人工全量手工执行+评分：按XX条指令/天，需XX人天 2、工具测评：全量执行3天+人工打分及结果确认 端到端测试效率提升2倍以上
TQL	TQL生成/解释/检视	XXXX		
代码	Python代码生成/解释/检视	XXXX		
	页面JS代码生成/解释/检视/续写	XXXX		
	Rhino JS代码生成/解释/检视/续写	XXXX		
模型	模型创建/调整/联动修改	XXXX	自动化打分+人工确认	
流程	流程创建/调整	XXXX		
UI	页面生成/组件生成/属性调整	XXXX		
	大屏生成/组件生成/属性调整	XXXX		

成果

- 1、测评集：基于copilot辅助编排能力，构建领域核心测评集**12600+指令，自动化泛化XX万**
- 2、工具提效：支持测评数据集在线管理和测试任务一键式执行+应用裁判模型自动打分和辅助评价，端到端提升测试效率**2倍以上**
- 3、版本发布：支撑ADC Code Agent能力快速上线，高效高质完成10个月度版本的测试上线，用户**满意度提升XX百分点**

1、测评集优化

- 现网用户数据收集，构建真实用户反馈的测试集，作为版本**必测的测试集**
- 筛选典型测试集，进行**高能耗点提效指标评估**
- 输入扰动因子库设计，**构建鲁棒性测试集**

2、结果测评

- 脚本类测试集当前对比参考答案与实际答案的评估方式不够准确，需进一步**优化评估方案**
- 测试集当前参考答案基本都是测试人员指定+专家评审，寻找**准确且快速**获取指令的标准答案/预期结果的方式

3、工具提效

- 将ADC领域制定的结果评估标准定制到大模型应用评测系统中，**精细化测试系统的评估方法&结果**
- 测试集**版本化管理**，自动识别轮次间测试异常结果

4、用户体验提升

- 分析运营埋点、运营看板数据，关注**用户高频场景的交互体验易用性**
- 与用户面对面交流，**测试伴飞**，收集用户反馈、诉求
- 深入用户资产编排场景，收集用户重点关注的ADC特性场景

道阻且长，行则将至；行而不辍，未来可期



谢谢
THANKS