

MTSC2025

中国互联网测试开发大会

TESTING SUMMIT CONFERENCE CHINA 2025

上海站

质效革新·智领未来

2025/7/12 | 上海喜来登由由大酒店 主办方: TesterHome

基于AI的智能用例生成在淘天业务的实践

讲 师 姚波

01

项目背景

02

项目现状与思考

03

AI用例生成&用例数据构造实践

04

当前落地效果


05

总结与展望

Part 1

项目背景





Part 2

项目现状与思考



需求产出

- 部分产品的需求质量不可控
- 需求反复沟通修改，信息不对齐

用例编写与管理

- 用例产出占测试工作量20 - 25%，逻辑理解&梳理&确认、异常&资损等场景构造、用例具体编写等工作费时
- 大部分人员还是传统的Xmind用例编写方式，无固定格式，用例核心资产无法管理与继承，新人复用困难，存在重复性的工作

测试数据准备

- 复杂项目依赖多个域的测试数据
- 各域工具专注域内数据构造，已有能力不透明
- 新老人对测试数据的熟悉程度天差地别

如何利用AI大模型能力助力质量保障提效



Part 3

AI用例生成&用例数据实践



- 整篇需求可能涉及淘宝全域业务，上下文语义理解并不依赖，甚至有互斥
- 底层模型的输入token有限制，整体输入会带来更多的模型不确定性
- 模型输出token的上限直接限制了用例输出的个数，全篇需求输入用例生成的覆盖度明显不足



理解需求背景

看看涉及哪些细分场域
和产品以及技术对齐改
动点和链路
按照细分场域生成用例

- ✓ 按照淘宝全域或者业务细分场域进行需求点拆分与补充，有效的格式与层级会帮助大模型更容易理解需求逻辑
- ✓ 并行调用模型生成用例并做用例合并
- ✓ 人工用例补全或者通过多轮对话交互补全用例

- 需求背景知识比较凝练，大模型无法完全理解
- 业务相关独有概念、定制链路、领域知识大模型无法完全理解
- 通用大模型针对测试设计相关领域知识的缺失



已经在业务中摸爬滚打许久，之前的相关需求已经了解过，新需求能很快理解


精通业务知识

一直在实践测试领域知识

- ✓ 资深的业务测试经验来源（历史需求、技术文档、历史用例）都需要做有效的沉淀，整合成有效的RAG知识库外挂
- ✓ 测试领域知识（边界值分析、等价划分、正交实验等）沉淀在Prompt中，作为用例生成的固化经验模板

用例生成&用例数据构造整体业务架构





结构化提示词

角色定义

目标指令

全局限制

设计流程

格式限定

少样本提示

避免模型
过度发散

引导模型使用
RAG和测试
领域知识

统一用例格式

结构化提示词

Role:
专家级软件测试员

Constraints:
- 用例需要全部输出，不能因为各种原因省略。
- 生成用例的具体数值时，不能出现逻辑和计算错误。
- 完成任务后即结束对话，不询问其他问题。

Goals:
- 分析需求文档，明确需求背景、业务场景、测试目标和要求。
- 根据测试功能点设计对应个数的测试用例，每个用例包含标题、前置条件、执行步骤和预期结果。
- 测试用例的输出符合Markdown格式，逻辑清晰、可读性高。

CaseLevelStandard:
- 设计的用例根据优先级从高到低可分类为P1、P2、P3用例。
- P1用例为涉及需求关键功能模块的用例，直接影响系统的核心业务流程，或可能导致重大缺陷的用例。
- P2用例为涉及支持性功能模块的用例，不直接影响核心业务流程，但对整体系统的运行有辅助作用。
- P3用例为边缘性功能相关用例，对系统整体影响较小，且出现缺陷的概率较低。

Workflow 【这里主要是讲Prompt中用例的设计流程，不是可使用的提示词】

1. 结合RAG召回的Top相关知识做需求重写，拆分成合适的上下段落
2. 参考<Examples>的用例生成经验，引入相关测试方法论，帮助模型整理出所有逻辑分支、功能点、条件等，比如正交实验、边界值分析等。
3. 二次确认RAG知识库内容的用例补充。
4. 用例逻辑 ReCheck。
5. 确定用例等级。
6. 为每一个用例分配相应的测试数据，增加用例的可读性。
7. 确定用例最终的输出格式规范

OutputFormat:

{序号}.测试标题：测试标题

用例等级：{等级}

前置条件:

- 前置条件描述 1
- 前置条件描述 2


执行步骤:

- 执行步骤1
- 执行步骤2


预期结果:


- 预期结果1
- 预期结果2

可参考：<https://langgptai.feishu.cn/wiki/RXdbwRyASiShtDky381ciwFEnpe>，<https://www.promptingguide.ai/zh>



通过大模型的理解能力结合平台能力，实现自然语言驱动测试数据生成，节省测试数据准备时间





Part 4

当前落地效果



项目中心 > AI-用例生成

1需求拆解

2模型选择

项目中心 > AI-用例生成

测试计划信息

TC编辑中 19829 演示

需求解析结果

需求拆解

模型选择

用例生成

4筛选采用

5进入测试

模拟用户短时间内多次触发红包请求，预期仅发放一次红包【异常用例】 P2 AI-Test

项目中心 > AI-用例生成

需求拆解

模型选择

用例生成

筛选采用

5进入测试

AI生成用例结果

AI生成被采纳用例数（含人工修正） 13

相对采纳率 (?) : 92.86% (13/14)

AI生成未经变更被采纳例数 13

绝对采纳率 (?) : 92.86% (13/14)

AI生成未被采纳用例数 1

冗余率 (?) : 7.14% (1/14)

人工补充用例数 0

人工补充占比 (?) : 0.0% (0/13)

当前选中用例0740-d05-74d-011006-cd4-0d4f5-01451 算法决策结果：对用户发放红包页面额为50元



相对采纳率

纳入使用的AI生成用例数（含变更和未变更） / 初版AI生成用例总数

这个指标反映了初版用例中有多少被纳入了最终版，无论这些用例是否经过了变更，它衡量的是初版用例的整体采纳情况



绝对采纳率

未经任何变更的AI生成用例数 / 初版AI生成用例总数

未经任何变更的AI生成用例：标题、前置条件、数据准备、执行步骤、预期结果的均未发生变更

这个指标反映了初版用例中完全未经过修改就被采纳的比例，它衡量的是初版用例的质量和稳定性



冗余率

AI生成未被采纳的用例数/初版AI生成用例总数


这个指标反映了AI生成的用例中有多少是无效或不必要的，它可指引AI模型进行进一步的优化



AI生成占比

纳入使用的AI生成用例数 / 项目用例总数（包含人工补充）

这个指标反映了AI生成的用例的最终覆盖度，是衡量模型用例生成推理能力的重要指标



Part 5

总结与展望





总结

- 用例是测试核心资产，需要做好管理和维护
- 用例数据构造依赖接口原子能力，需要在项目测试过程中尽量积累
- 用例生成在整个测试周期内的时间占比重，有比较大的优化空间
- 文本理解、推理、生成是目前大模型的优势项，在用例生成上能更好的落地



展望

- 用例生成模式上可以基于Copilot多轮对话的方式帮助模型提升用例覆盖率
- 目前AI用例生成是基于文本 + 表格的方式来理解需求，后续需要探索流程图 + 交互稿全方位解析的方式帮助大模型更深入的理解需求
- 基于现有的AI用例生成规范和RAG知识库做存量用例的自动更新和规范
- 用例自动执行与校验

谢谢
THANKS