

MTSC2025

中国互联网测试开发大会

TESTING SUMMIT CONFERENCE CHINA 2025

上海
站

质效革新·智领未来

2025/7/12 | 上海喜来登由由大酒店 主办方: TesterHome

MTSC2025 中国互联网测试开发大会 上海站
TESTING SUMMIT CONFERENCE CHINA 2025

AI大模型驱动算法评测的“效能革命”

陈曦文

质效革新·智领未来

主办方: TesterHome


目录

- 1 背景
- 2 评测全流程的效能革命
- 3 应用案例
- 4 挑战与展望

01 | 背景

➤ 现状


当前支付宝各业务线DAU较大，传统依赖人工质检与小模型的评测方式已难以应对当前海量数据的实时性与精准性要求。



➤ 传统算法评测痛点

- 1. 数据收集：依赖真实场景数据，成本高、样本不足，难以覆盖边缘案例
- 2. 离线评测：人工标注耗时长，小模型泛化能力差，问题归因依赖专家经验
- 3. 业务上线：多轮人工审核导致流程冗长，用户体验差（如广告/电商生成图审核周期长）
- 4. 线上巡检：人工回流数据耗时，问题归因不系统，报告生成效率低


AI时代变革



从此进入AI大模型时代，实现从“专用模型”到“通用智能”的跨越。



AI 1.0

- 定义：数据驱动下的技术架构与智能化范式。
- 典型场景：图像识别、语音识别、自然语言处理等。
- 应用范式：基于领域内数据构建判别式AI小模型，完美展现专家经验。
- 局限性：需要大量标注数据，泛化能力弱，可解释性差。



AI 2.0

- 定义：利用大模型的生成能力和推理能力，带来新的应用范式。
- 典型场景：ChatGPT、Copilot等。
- 应用范式：训练一个巨大的生成式大模型，大模型驱动业务决策
- 局限性：训练资源消耗巨大，存在不当使用和模型偏见问题。



通过预训练+微调范式，轻量化训练业务大模型


02 | 评测全流程的效能革命

一、数据集构建

传统方式：依赖于开源数据、业务数据、或真实场景采集，成本高、样本有限，难以覆盖极端案例



AI注入：基于sd模型或虚拟仿真技术，生成“不存在的badcase”，低成本构建海量样本。



不再局限于真实场景及传统的数据增强方式，提升覆盖度的同时，极大地降本增效

MTSC2025
中国互联测试开发大会
TESTING SUMMIT CONFERENCE CHINA 2025

上海站




三、业务上线

传统方式：




• 客观评测




• 主观评测



AI注入：




自动化评测框架



一级类	二级类	具体	优势
客观指标	无参考	清晰度、信噪比等	
	有参考	SSIM等	
主观指标	美学	基于VGG、Inception或MobileNet的MOS打分模型	
	(新) 观赏性-美学 from (AI生图创造性强)	基于CLIP (ViT) /BLIP的MOS打分模型。	• 场景更通用，泛化能力更强，细节捕捉能力up。 • 可结合文本信息
	(新) 可控性-一致性 from (AI生图可以交互)	CLIPScore、ImageReward等	提供文图/图图一致性判断能力。
	(新) 观赏性-异常 from (AI生图技术瓶颈)	GIT、LLaVA等	提供异常发现的能力。

人审提效70%，全流程耗时降至小时级，助力用户体验与业务效率双提升

四、线上日常巡检



人像质量服务-调用量

当日调用量 - amic50900002

步骤一：用户无过没有数据集人像质量服务的读权限，请联系灵竹分享数...

步骤二：如按上述步骤仍未解决报错问题，请 复制tracelid 联系 研发小

人像质量服务-成功率

占比图

amic50900002

步骤一：用户无过没有数据集人像质量服务的读权限，请联系灵竹分享数...

步骤二：如按上述步骤仍未解决报错问题，请 复制tracelid 联系 研发小

人像质量服务-耗时

小时平均耗时 - amic50900002

步骤一：用户无过没有数据集人像质量服务的读权限，请联系灵竹分享数...

步骤二：如按上述步骤仍未解决报错问题，请 复制tracelid 联系 研发小

人像生成服务-调用量

人像生成服务-耗时

多音字读错

英文缩写读错

数字符号读错

数字符号漏读

网址读错

中英文漏读

重复读

词间停顿错误

03 | 应用案例


广告AIGC场景应用 — 评测难点与挑战

AIGC产物新问题点：

- 现实世界不存在或不常见【异常】
- 与用户意愿不相符【一致性】
- 主观感受不佳【美学】

广告场景下：

- 主体生成前后改变【一致性】
- 与客观事实不符【美学】
- 主背景不协调【美学】



主体物出现bug			产品角度与模版不匹配			无投影产品		
背景发生扭曲			分割多品不要放在台面上			背景杂乱		
背景生成出异物			场景与物品美观度不匹配			产品悬空		


广告AIGC场景应用 — 大模型思路

- 建设思路：“魔法打魔法”的思路，用大模型测大模型
- 测评大模型：基于CLIP(ViT)、LLaVA等业界前沿的大模型训练框架和底座，结合开源数据集以及支付宝自营业务场景标注数据，训练一套蚂蚁自己的AIGC生图测评大模型VQAGPT，对AIGC生图产物进行自动化评测质检。

VQA-GPT:


Visual Quality Assessment General Pretrained-models

大模型测评




VQA-BD

VQA-GPT




VQA-Toolkit + CLIP-SDft



VQA-AS

VQA-GPT 一致性判断

- ✓ 判断生成前后商品主体是否一致
- ✓ 可视化问题区域，提高模型对特定问题发现的辨识度



线上拦截商品主体出现异常突变的生成图，拦截准确率90%+

原图	生成图	模型过滤原因
		主体不一致： 茶壶上面的盖子少了一部分
		主体不一致： 右图中，左边的拖鞋多了一部分， 且鞋子里有异常白色的填充物
		主体不一致： 清洗机最下面的拖布那里少了很大一块
		主体不一致： 额外生成了橘子

VQA-GPT 美学判断

原图	生成图	模型过滤原因
		主背景不协调： 颜色不协调，蓝灰色的电风扇放在深灰色的背景里
		主背景不协调： 黑色的鞋子用灰色的背景，对比度差，缺少底部光影
		主背景不协调： 背景杂乱且与充电宝这一产品不匹配
		主体不一致： 衣服左侧的袖子多出来一块布料

- 专家美学：从更专业/抽象的视角（专家视角）来评测一张图的美，比如莫奈的睡莲等抽象派大师的作品。



图2 抽象派作品示例

- 大众美学：从普通大众的喜好来评测一张图的美，比如随手的一张自拍。




图3 大众摄影作品示例

训练集：

开源+业务美学标注数据规模10w+


IAQA评测维度	清晰度*2	色彩饱和度*1	光线*1	黄金比例	重复
—— 客观角度	（图片是否有模糊情况）	（图片是否过饱和、过于鲜艳）	（光线是否过暗/过亮）	（主体位于三等分处）	（是否存在模块重复部分）
	0/1	0/1	0/1	0/1	0/1
IAQA评测维度	主体美感	背景美感*3	画风一致	主体一致	场景一致
—— 主观角度	（人：五官/形态；物：光泽/形状）*3		【AIGC】	【AIGC】	【AIGC】
	0/1	0/1	0/1	0/1	0/1




广告AIGC场景应用 — 业务效果

指标	数值	风险&&方案	备注
过滤精确率 ↑	97.2%	-	过滤100张图中，约3张误杀。(具体图示在定性分析中)
过滤召回率 ↑	23.1%		
优质图召回率 ↑	96.4%	- 风险：约3%优质图会被误过滤，可能会导致某些品类AIGC覆盖率降低； - 方案：补图阶段会降低该风险，后续过滤模型会持续优化。	
人审图片基数 ↓	8372-> 6692 + 251(补图) = 6943	-	人审图片数降低 20% (补图的话17%)
人工/机审ad_id保留率 ↑	人工：55.1%(177/321) 机审：98.1%(315/321)		1、人工审核也会导致ad_id数降低； 2、机审ad_id降低种类中的2个与人审ad_id降低种类有出入，详见3.3
人工/机审核效率 ↓	17.63s/1.86s per image		

上线前



上线后



在算法上线前充分验证机审能力，上线后持续优化，实现高效可靠的AIGC图像质量检测体系，为人审提效20%+。

自动化评测平台

功能1：美学异常检测，用户可以上传单/多张图片(url)，来实现检测




功能3：图图一致性检测，用户可以上传图片-图片对，来实现检测



功能2：图文一致性检测，用户可以上传图片 and 对应文本，来实现检测



功能4：任务中心提供多种检索方式，用户可查看所有上传图的评测结果




功能5：统计中心为用户提供各指标的分级统计结果，如异常率的高/中/低分级、一致率的优/中/差分级等

功能6：评测样本集管理



样本集ID		样本集名称		样本数量		样本类型		创建人			
48000063		ffhq		13061		图像		棋旗			
- 图片评测		3600012		-				太玄			
美学分		3600013		-				太玄			
图文一致		3600014		-				太玄			
图图一致		3600015		-				太玄			
- 人像评测集		3700001		-				棋旗			
+ 发型		3700002		-				棋旗			
脸型		3900001		-				棋旗			
年龄		3900002		-				棋旗			
表情		3900003		-				棋旗			
视角		3900004		-				棋旗			
遮挡		3900005		-				棋旗			
用户图	细粒度属性		用户图	细粒度属性		用户图	细粒度属性		用户图	细粒度属性	
	{ "url": "xxx", "attributes": { "hair": "短发", "year": "6岁以下", "sex": "男", "skin_color": "白皙", "face_shape": "瓜子脸", "emotion": "平常", "vision": "正面", "block": "嘴巴遮挡" } }			{ "url": "xxx", "attributes": { "hair": "短发", "year": "18-26岁", "sex": "男", "skin_color": "黝黑", "face_shape": "瓜子脸", "emotion": "平常", "vision": "正面", "block": "眼镜-普通眼镜" } }			{ "url": "xxx", "attributes": { "hair": "长发", "year": "26-50岁", "sex": "女", "skin_color": "黄色", "face_shape": "瓜子脸", "emotion": "平常", "vision": "侧面", "block": "无遮挡" } }			{ "url": "xxx", "attributes": { "hair": "长发", "year": "18-26岁", "sex": "女", "skin_color": "白皙", "face_shape": "瓜子脸", "emotion": "平常", "vision": "正面", "block": "额头厚刘海" } }	
	{ "url": "xxx", "attributes": { "hair": "长发", "year": "26-50岁", "sex": "女", "skin_color": "黄色", "face_shape": "瓜子脸", "emotion": "平常", "vision": "侧面", "block": "无遮挡" } }			{ "url": "xxx", "attributes": { "hair": "长发", "year": "18-26岁", "sex": "女", "skin_color": "白皙", "face_shape": "瓜子脸", "emotion": "平常", "vision": "正面", "block": "额头厚刘海" } }			{ "url": "xxx", "attributes": { "hair": "短发", "year": "6岁以下", "sex": "男", "skin_color": "黝黑", "face_shape": "瓜子脸", "emotion": "平常", "vision": "正面", "block": "无遮挡" } }			{ "url": "xxx", "attributes": { "hair": "短发", "year": "70岁以上", "sex": "男", "skin_color": "黄色", "face_shape": "长脸", "emotion": "平常", "vision": "侧面", "block": "眼镜-普通眼镜" } }	



04 | 挑战与展望

➤ 大模型落地过程中，仍面临以下挑战

1. 虚拟仿真数据的“真实性”与“多样性”平衡
2. 大模型部署的算力成本与实时性矛盾
3. 如何合理、高效地让大模型普适业务

展望


➤ 技术深化

1. 轻量化模型：边缘计算部署（如移动端实时质检）
2. 多模态融合：文本、语音与图像的联合评测
3. 应用拓展：助力AI评测能力成为行业基础设施，推动“零人工干预”流程


➤ 降本增效：通过自动化评测释放资源，聚焦核心业务创新

能力大图

公众号



公众号



Q&A

谢谢
THANKS