

MTSC2025

中国互联网测试开发大会

TESTING SUMMIT CONFERENCE CHINA 2025

上海
站

质效革新·智领未来

2025/7/12 | 上海喜来登由由大酒店 主办方: TesterHome

MTSC2025 中国互联网测试开发大会 上海站
TESTING SUMMIT CONFERENCE CHINA 2025

大前端智能化测试：技术演进与实践探索

讲 师：郭诗雨

质效革新·智领未来



主办方：TesterHome

目录

- 一、大前端测试流程
- 二、大前端测试的挑战与痛点
- 三、技术演进与实践探索
- 四、未来趋势与挑战

一、大前端测试流程

测试过程可以概括为：

- 1.测试设计与准备（测什么）
（用例生成、选择与筛选、精准测试）
- 2.测试执行与验证（怎么测）
（环境搭建、驱动执行、结果校验）
- 3.测试评估与优化（测的怎么样）
（覆盖率分析、效率评估、状态跟踪）


针对「测试执行与验证」：

手工测试通常用来做新需求测试，但人力成本较高，在回归测试等场景难以大规模开展。为弥补手工测试的不足，业界引入了传统UI自动化测试，旨在降低成本、扩大覆盖范围并提升效率，较多应用于回归测试等场景。

一、大前端测试流程

UI自动化测试的「额外工作」

- 手工测试**：测试人员根据需求，设计、维护测试用例集；依照用例集对测试用例逐条操作、观察、判断，并记录结果；
- UI自动化测试**：测试人员根据需求，设计、维护测试用例集；利用自动化框架（如Appium、UIAutomator、Playwright等）将驱动和验证逻辑编写与维护测试用例代码；执行完自动化后人工确认自动化结果。



二、大前端测试的挑战与痛点

传统UI自动化测试存在的诸多问题：



测试效率瓶颈

- UI自动化用例开发维护成本高
- 可迁移性差（跨平台复用率低）
- 鲁棒性不足（稳定性与准确率低）

前端技术复杂性


- 框架多样性
- 设备碎片化
- 多端多技术栈适配投入冗余

二、大前端测试的挑战与痛点

目标：

利用智能化能力，探索低成本、高效的UI自动化解决方案，提升大前端测试整体的效率。

三、技术演进与实践探索



自2022年11月起，我们迅速调整建设策略，结合LLM、Agent等技术，围绕实际业务需求，完成了大前端智能化测试领域多个能力原型建设，主要围绕**自动化测试的执行**建设了包括智能遍历测试、UI内容一致性检测、AUITestAgent智能化自然语言UI驱动校验、智能UI异常检测等，并在门票、沉浸式视频、服务零售等多个业务方向成功落地，大幅提升了测试效率并检出100+个有效缺陷。

三、技术演进与实践探索

3.1 测试环境准备

场景数据集

住宿列表页场景1
mp://wx7649daed8f2335c4/pages/suggest/index?cityId=1&locateCityId=1

mock数据 深度链接

被测应用

美团 小程序

已支持可测性改进的应用包



云端设备批量执行



测试结果

case名称 创建活动

case详情 1.点击'首住折扣'并等待进入下一屏2.点击'新增促销规则'并等待进入下一屏3.点击'全选'前的勾选框，并点击下一步并等待进入下一屏4.点击下一步，并等待进入下一屏5.点击第一个'请选择'输入框等待

操作次数 21

执行结果 通过

结果详情 应达1.过性中的1.少录，涉及选择产品、设置库存、配置折扣，最终确认设置，如在第19和20页上显示的"提交"按钮所示。完成所有步骤表明任务所需的主要测试导航和交互已成功执行。

三、技术演进与实践探索

3.2 智能化遍历测试

针对端上应用执行交互的稳定性与功能性检查。与传统的遍历工具（如Monkey）相比，智能化遍历测试不仅检测Crash、JSError等硬性异常，还基于用视觉模型和大模型的能力，能够识别检测黑白屏、加载失败、以及交互结果不符合功能预期等问题。

适合与传统测试配合，通过大量运行发掘现有人工\自动化测试用例以外的异常场景，同时也比较适合对质量问题较多的新业务、新平台、新系统进行自动化低成本问题挖掘（如鸿蒙等）




三、技术演进与实践探索

3.2 智能化遍历测试

创新点:


- 1.利用LLM预测被交互节点功能，并判断交互后页面是否符合功能预期
- 2.利用SoM标注节点，提高小杯模型(如4o-mini/claude-haiku)性能，兼顾成本与准确率



三、技术演进与实践探索

3.2 智能化遍历测试

步骤一： 预测节点功能

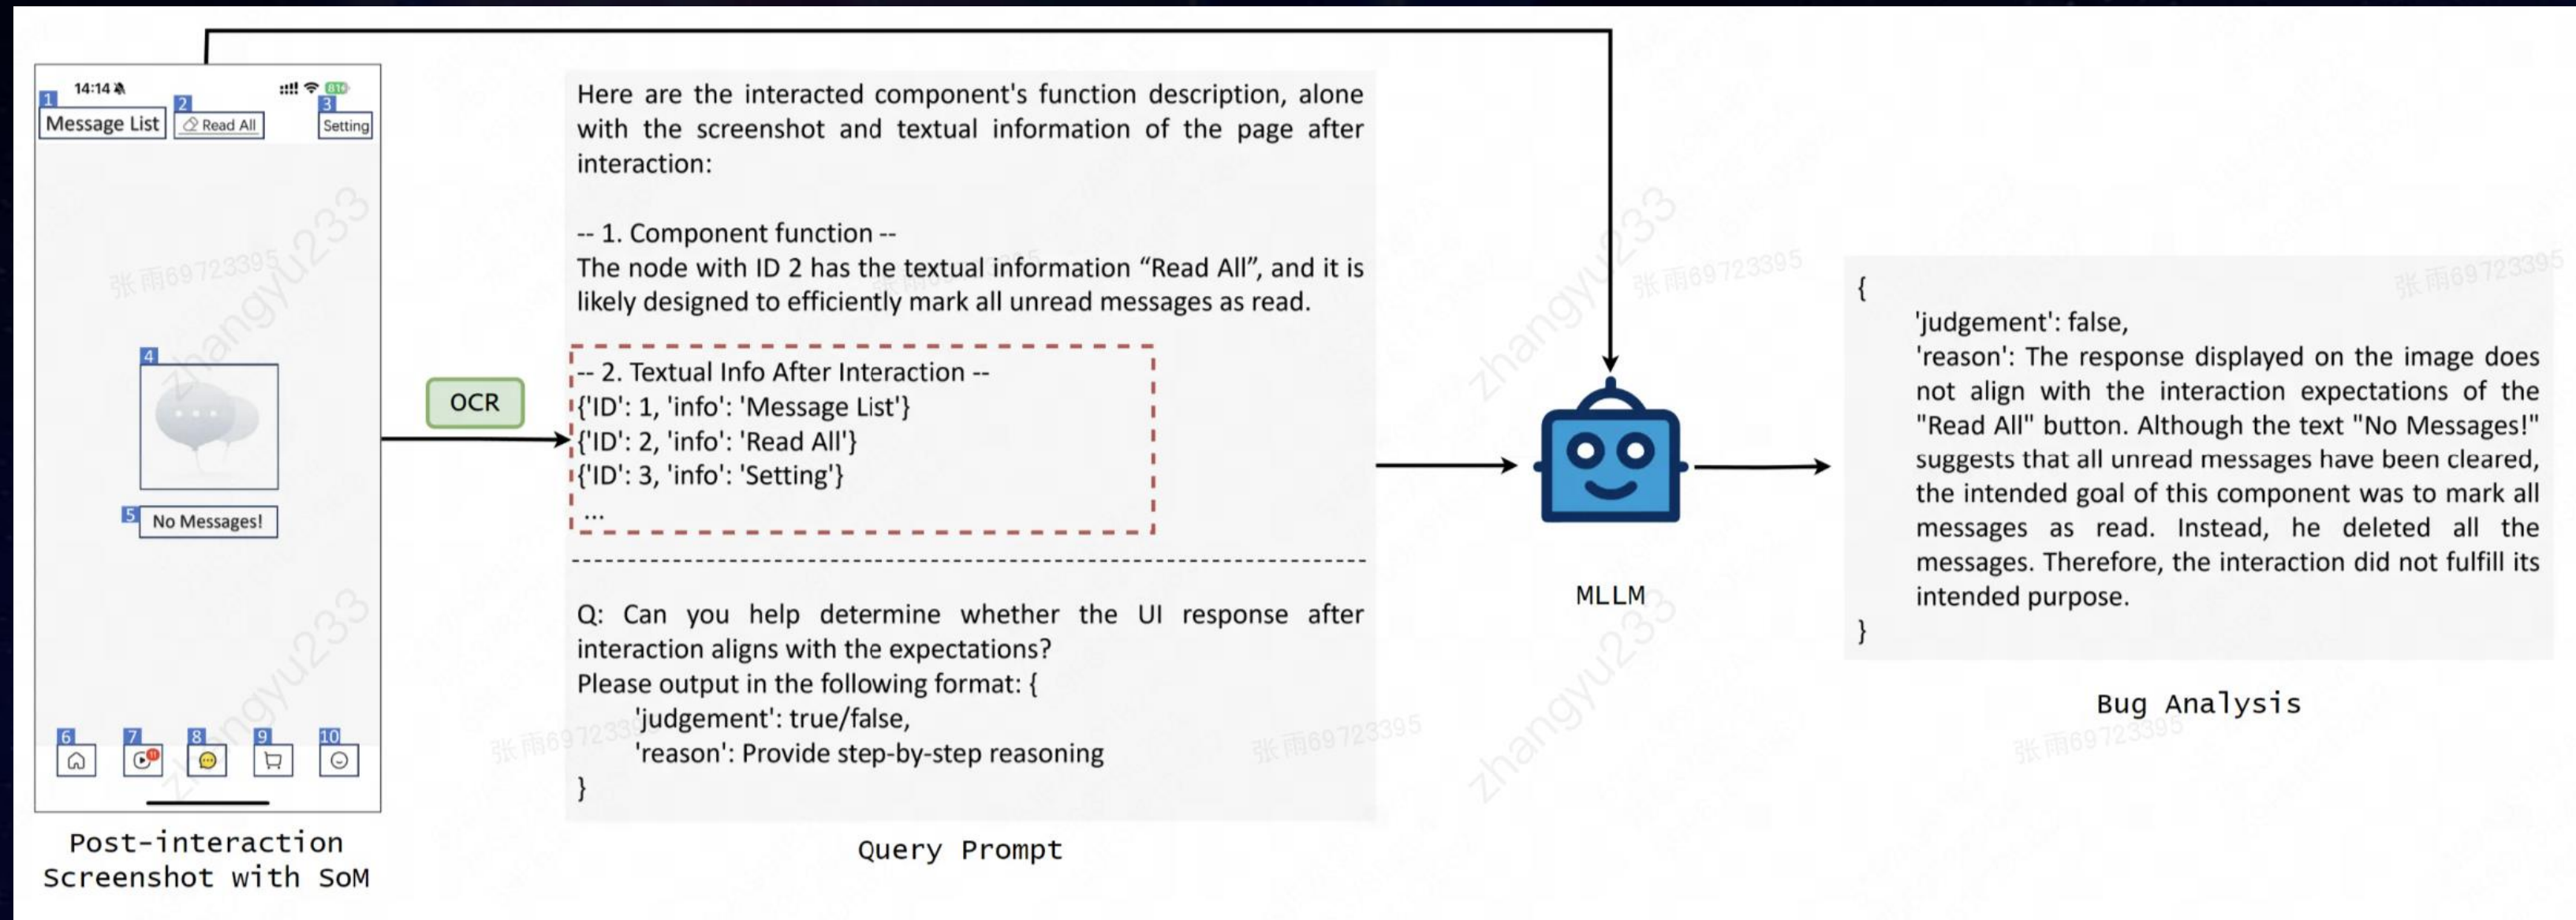


三、技术演进与实践探索

3.2 智能化遍历测试

步骤二：

判断交互后页面
响应是否符合预期



三、技术演进与实践探索

3.2 智能化遍历测试

指标

bug召回能力评估：针对明显异常情况（如RN报错、APP崩溃、黑白屏、返回APP首页、停留扫码配置页等）可做到99%+召回。针对通识类bug异常（LLM判断），召回率在80%以上，整体校验准确率为91%。

三、技术演进与实践探索

3.2 智能化遍历测试

业务实际落地效果

智能化遍历测试总体运行时长1w+小时，共执行了50w+个自动化测试用例，接入22个业务方向，其中17个方向深度使用。至今已发现了**100+**个有效缺陷。

技术与学术影响力

发表国际软件工程领域顶会 ICSE 2025 (CCF A) 论文一篇：

[KuiTest: Leveraging Knowledge in the Wild as GUI Testing Oracle for Mobile Apps](#)

三、技术演进与实践探索

3.3 智能化一致性校验

同一类业务元素信息分散在不同团队负责的页面内，存在页面中的UI信息相互矛盾（如右图中同一个商品在多个页面上的实际价格不一致）此类UI内容不一致的异常，长期以来主要依赖测试人员对于UI的熟悉度，靠手工测试执行时来随机进行发现。

会场页

详情页

提单页

UI界面

张雨12090837

张雨12090837

张雨12090837

价格信息不一致

¥11.99

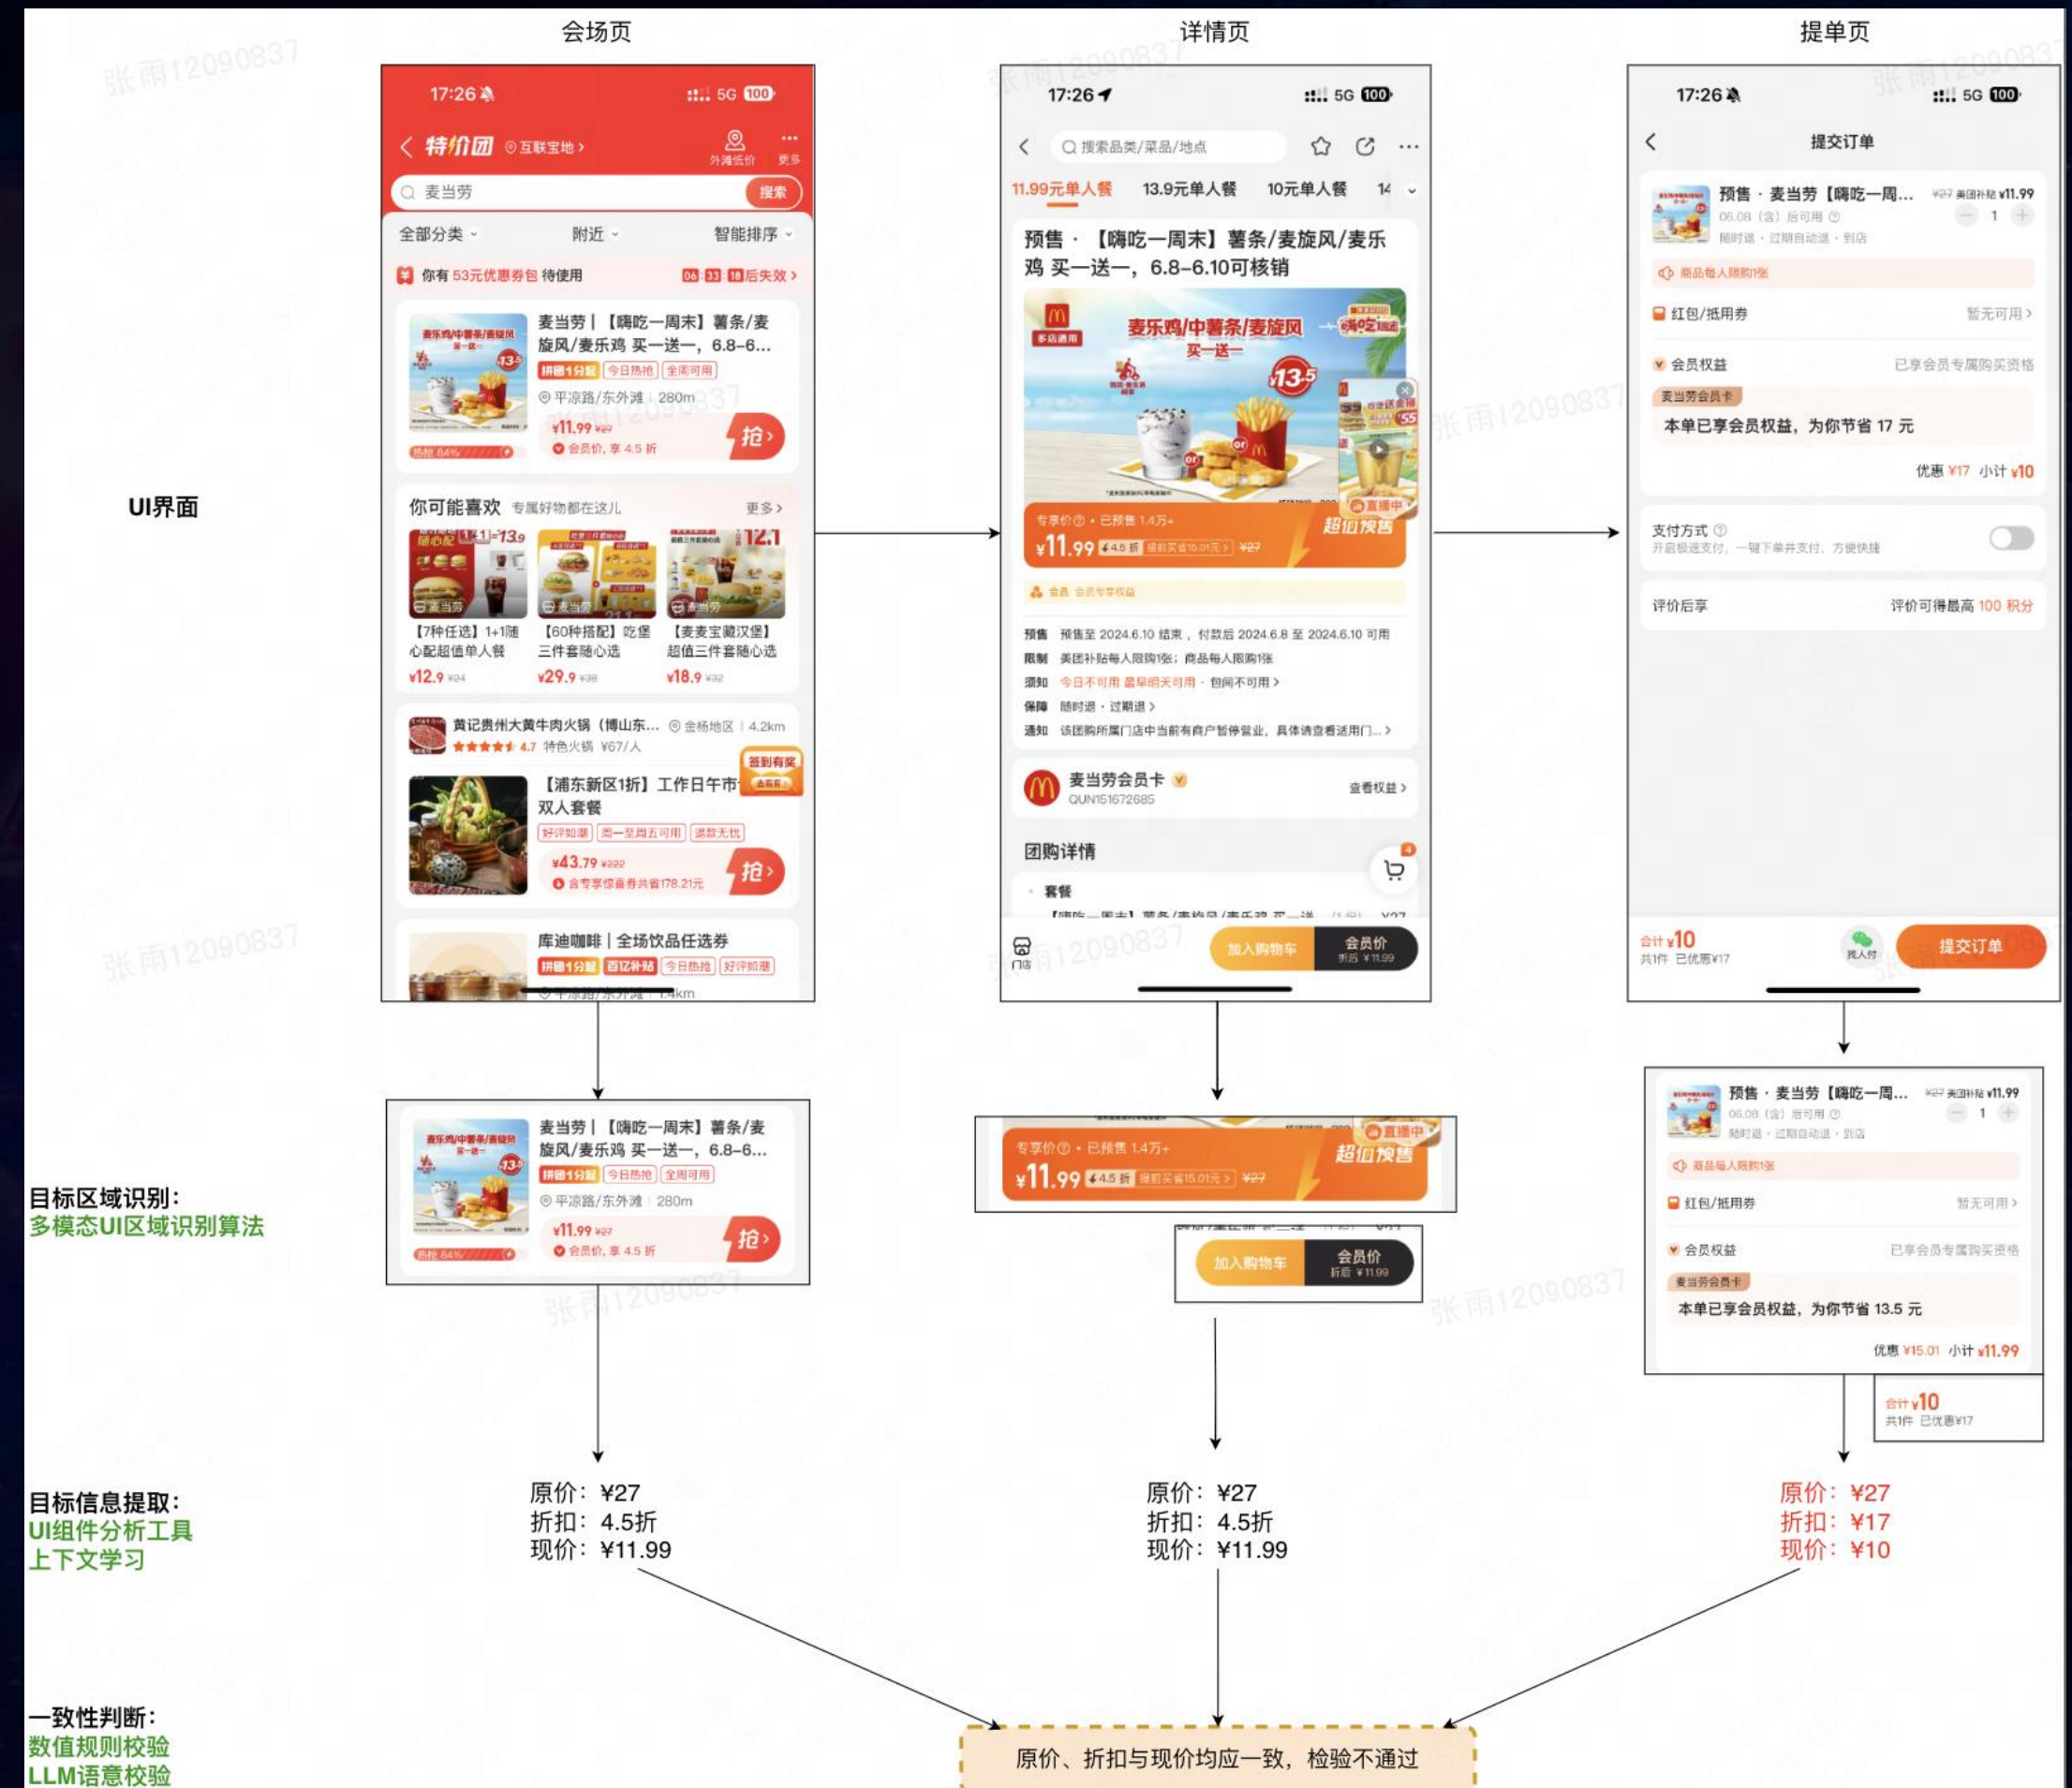
¥11.99

¥10

三、技术演进与实践探索

3.3 智能化一致性校验


为解决该问题，我们针对UI层面设计并实现了一套自动化智能检测流程，名为AutoConsis，在UI内容一致性检测上做到了低成本、高泛化性、高置信度。



三、技术演进与实践探索

3.3 智能化一致性校验

内容一致性校验本质是对UI页面的**特定信息提取**，价格一致性采用的也是信息提取流程。我们将UI页面分析任务转化为**目标检测和内容理解的组合**，利用了**大语言模型的能力**，实现对不同技术栈页面的适应能力。



三、技术演进与实践探索


3.3 智能化一致性校验

AutoConsis有三个关键处理流程：

1.目标区域识别： AutoConsis首先识别UI界面中与检测相关的关键区域。通过图像处理和模式识别，工具能够准确地定位到包含重要信息的UI部分。

2.目标信息抽取： 在目标区域确认后，经过OCR和UI组件分析工具 提取目标区域的文本和元素，填入预先设置好的CoT Prompt，通过大模型推理提取一致性校验所需要的关键信息。


3.一致性判断： AutoConsis对提取出的信息进行一致性校验，确保UI信息的准确性和一致性。



三、技术演进与实践探索

3.3 智能化一致性校验

步骤1: 目标区域识别

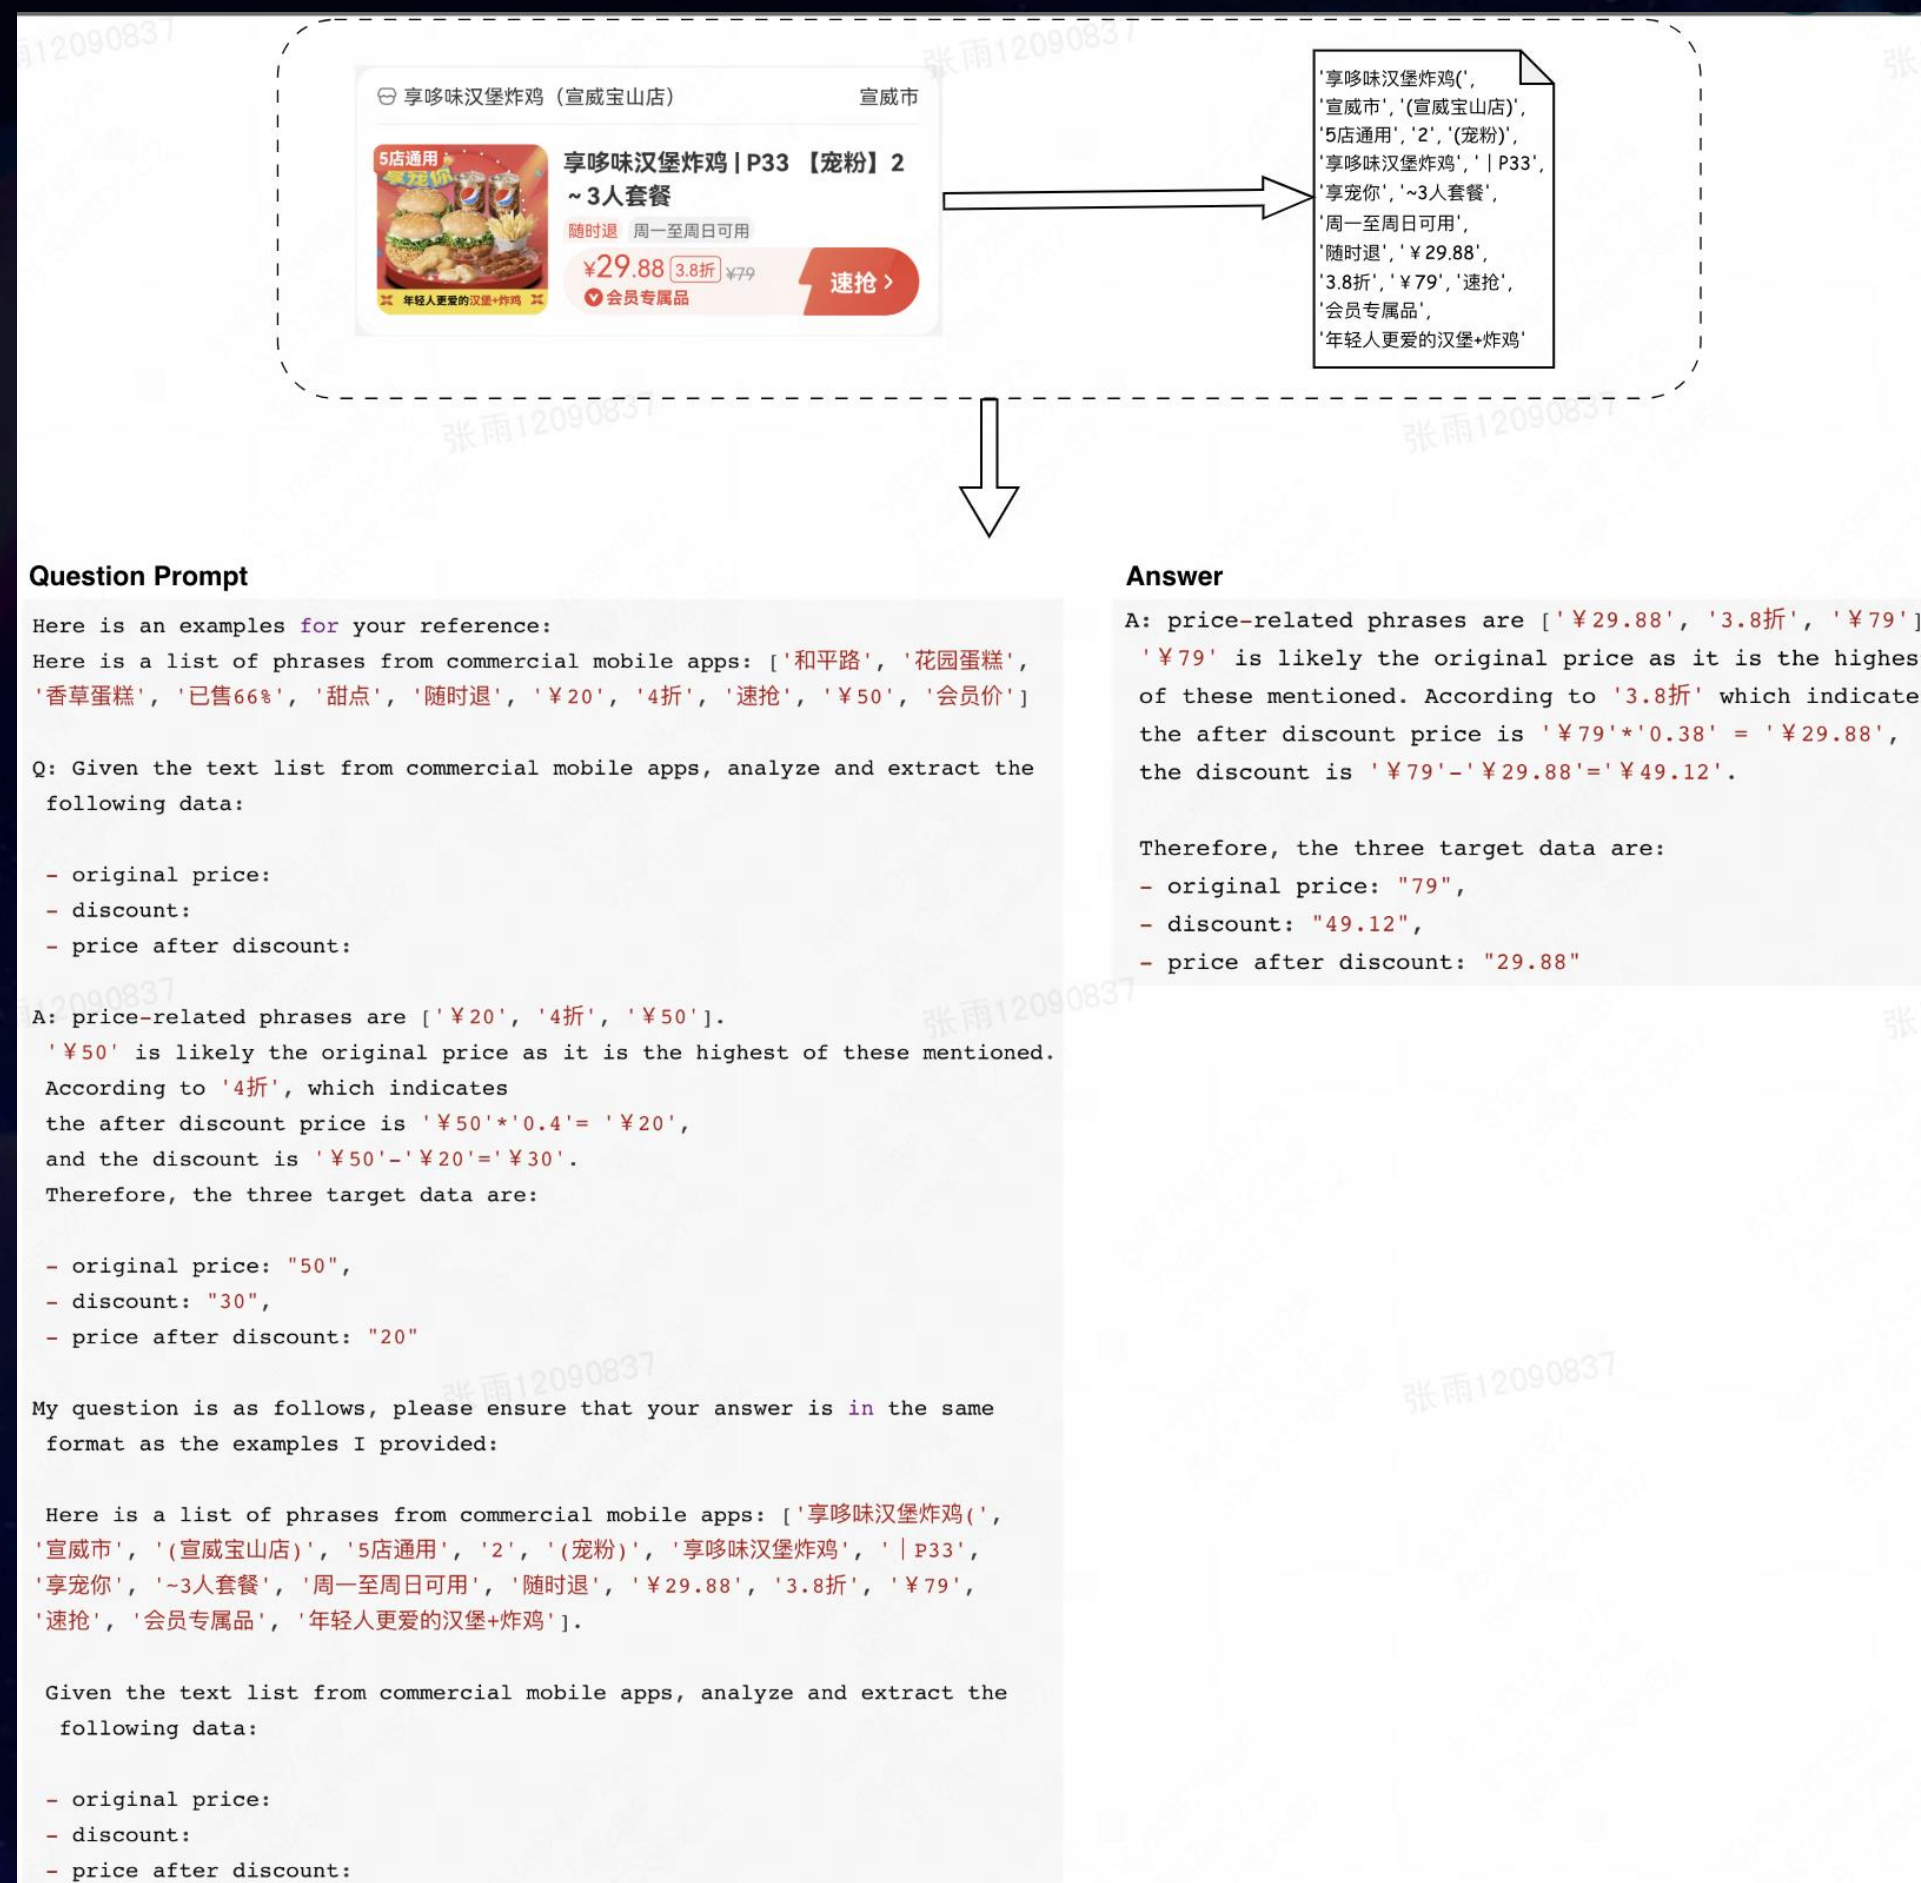


三、技术演进与实践探索

3.3 智能化一致性校验

步骤2: 目标信息提取

通过OCR识别商品文本信息，通过CoT提示推理过程，让大模型预测当前展示的商品原价+折扣+折扣后价格



三、技术演进与实践探索

3.3 智能化一致性校验

步骤3: 信息一致性校验



3.3 智能化一致性校验

指标

方法	准确性	单页面推理速度	单页面成本	1000页面综合成本
AutoConsis	0.94	2s-3s	0.018元 - text token	1小时 2元
GPT-4V	约0.85	45s	2.5元 - image token	15小时 2500元

AutoConsis作为一整套一致性检测流程，相比于直接应用MLLM作为整体UI图像输入来判断，适配的复杂度会更高一些。但从结果看，AutoConsis在执行效率、检测结果的可靠性、执行成本三个方面均更具优势。当前业务一次巡检需在几千量级的页面规模上使用，所以我们选择AutoConsis来批量进行业务应用落地。

三、技术演进与实践探索

3.3 智能化一致性校验

业务实际落地效果

特价团购巡检：该能力在美团特价团购营销会场场景上覆盖了**700+**城市、**4000+**多页面，在项目开城与后续迭代过程中，持续以巡检形式执行，期间共发现**20+**个有效业务问题。

门票运营活动巡检：分析页面所有可能有运营的位置，点击后判断内容和活动是否一致。目前已在12个城市的200+个页面上进行使用，共计发现了**10+**个有效问题。

技术与学术影响力


发表国际软件工程领域顶会 ICSE 2024 (CCF A) 论文一篇：

[AutoConsis: Automatic GUI-driven Data Inconsistency Detection of Mobile Apps](#)

三、技术演进与实践探索

3.4 AUITestAgent智能交互测试

聚焦于**UI测试**的
GUIAgent。
用户可通过输入自然语言形式的**交互指令**与**检查指令**，让AI帮助完成端上交互的执行以及交互后结果的检查。



三、技术演进与实践探索

3.4 AUITestAgent智能交互测试

AUITestAgent的适用场景与定位：

1. 聚焦交互的功能回归测试

- 针对于需求迭代，希望快速建立自动化进行重交互的功能检查覆盖。

2. 定制化的线上巡检


- 针对线上场景，存在特定的检查规则，希望快速构建客户端自动化巡检。

三、技术演进与实践探索


3.4 AUITestAgent智能交互测试

创新点:

提出双路架构，在执行操作同时抽取测试相关信息，并在最终进行结果校验



3.4 AUITestAgent智能交互测试-流程原理



三、技术演进与实践探索

3.4 AUITestAgent智能交互测试-Case书写规范

基本原则

- **清晰性 (Clarity):** 指令应明确无歧义, 准确描述每一个操作步骤。
- **完整性 (Completeness):** 任务应包含从起始状态到目标状态的所有必要步骤。
- **原子性 (Atomicity):** 每个独立操作应尽可能拆分为一个指令步骤。
- **顺序性 (Sequentiality):** 严格按照操作的先后顺序书写指令。

三、技术演进与实践探索

3.4 AUITestAgent智能交互测试

指标

使用美团场景下的不同难度等级的自然语言Case的数据集进行评测。

指标	准确率
Task完成率	L1简单case完成率在 95% 以上，L3困难case完成率在 66% 以上。
执行效率	单步耗时约 25s
测试任务校验准确率	整体在 85% 以上

三、技术演进与实践探索

3.4 AUITestAgent智能交互测试


技术与学术影响力

博客：[技术博客：一句话让AI帮你做UI测试，多模态测试智能体AUITestAgent](#)

三、技术演进与实践探索

3.5 智能UI异常检测

大前端智能UI异常检测指App/Web UI界面的自动化异常检测，不限技术栈，分为有参考和无参考两个分类，为Hyperjump视觉自动化，遍历测试，垂直测试提供UI检测能力，部分能力以服务接口的形式提供其他团队使用。




三、技术演进与实践探索

3.5 智能UI异常检测

有参考UI检测:

有参考检测指基于参照物如**基准图/断言目标**，能够携带专业业务知识做**深入性的检测**，支持高精度的行特征比对和具有自适应性的图像语义断言两个检测模式，同时标记当前图和参考基准不同的地方，是**自动化回归测试的核心检测能力**。



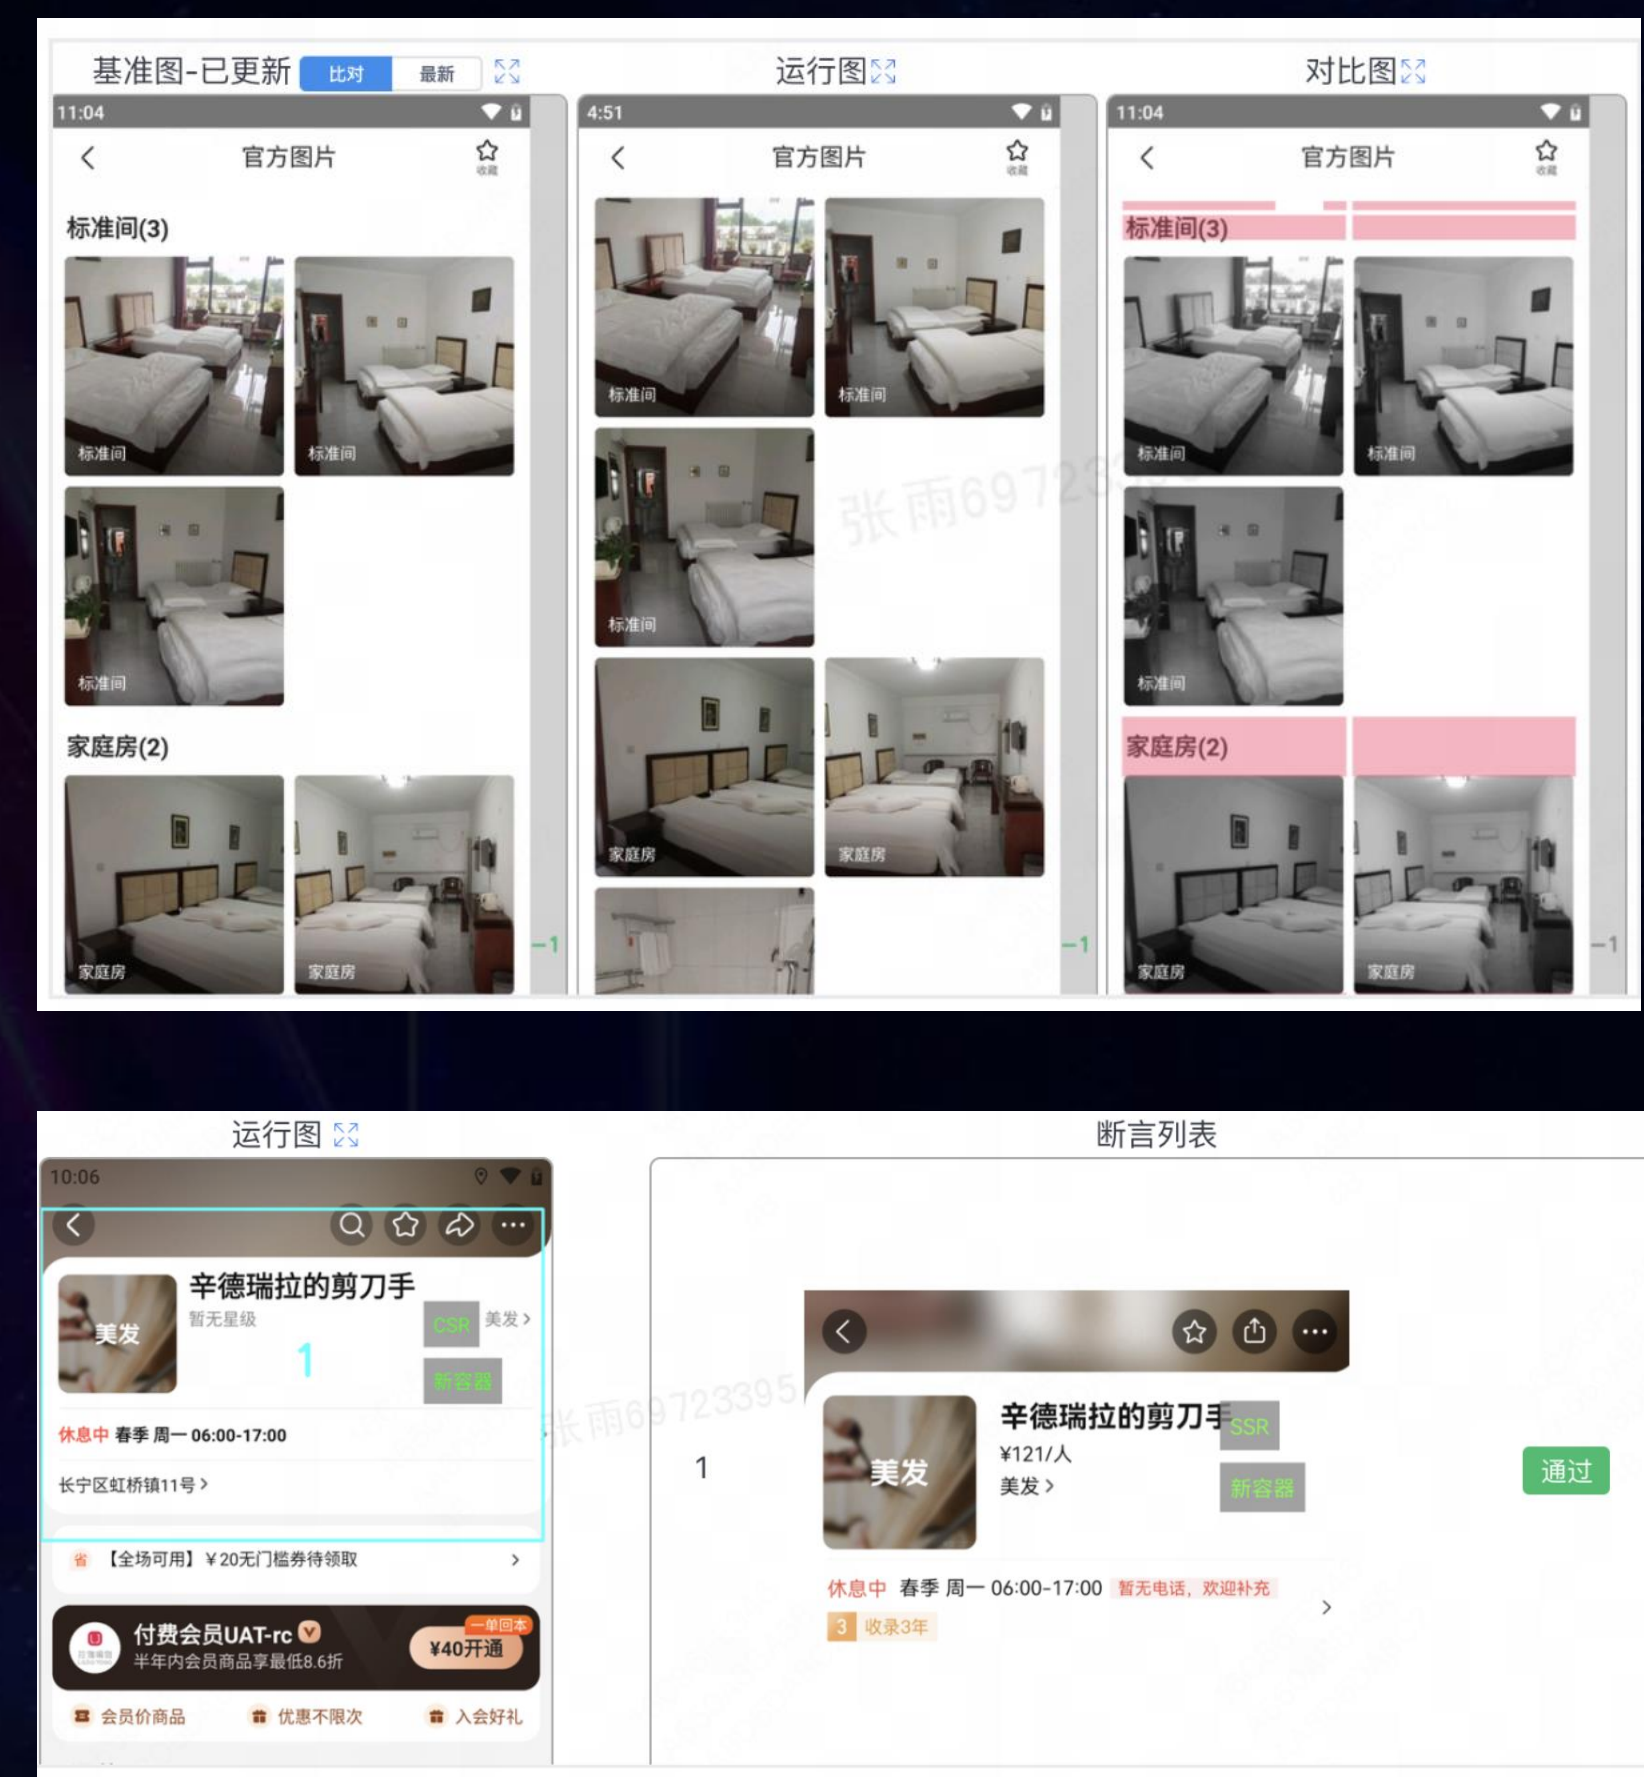
三、技术演进与实践探索

3.5 智能UI异常检测

有参考UI检测：

业务实际落地效果

平均每天检测**2w+**个场景，基本覆盖到店全量测试场景，同时应用于美团平台、金融、地图、买菜业务，经过对比去噪后评估对比噪声在小于10%，近一年在到店范围帮助业务发现**150+**个问题



三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：

指自动识别通识性的UI展示异常，无配置和维护成本，当前已支持了如数字异常，文本重叠遮挡，模块渲染异常检测能力。针对UI异常如文本遮挡 / 乱码 / 重叠 / 模块空白等进行检测。

无需配置，检测点明确且专一。

文字遮挡



模块渲染



文字重叠



三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：多模态模型微调

UI问题属于局部问题检测，最常见的是训练一个**目标检测模型**。模型的训练一般需大量的标注数据，可实际场景一般标注数据很少，我们的前代方法（yolo）通过数据合成，微调目标检测模型实现了检测方案，但是在应用过程中发现对于真实问题召回率较低。

分析原因，传统深度模型如目标检测适合识别局部特征，**不具备人类对UI页面举一反三的理解能力**。同时UI发版更新快，由于无法预测UI问题的真实分布，合成训练数据对比实际场景存在区别，局部特征拟合因此失效。



三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：多模态模型微调

近年来随着多模态大语言模型的发展，特别是R1推理模型的成功，我们看到模型在语义理解层面的潜力，语义理解能够突破局部特征的限制。
多模态模型是否能够模拟人类对UI的观察视角？
我们仅使用少量的标注数据实现了多模态模型的微调，**最终在UI异常检测领域取得的效果不仅相比前代方法有很大提升，对比GPT4o等通用模型也具有明显优势**，以下介绍建设的过程和思考。




三、技术演进与实践探索

3.5 智能UI异常检测

效果评估与示例

截断场景

长宽比和训练数据相反



SFT

```
<think>
首先观察页面整体布局...</think>
<answer>页面不存在UI展示问题。</
answer>
```

SFT和GRPO

```
<think>
从截图中可以看到，顶部的筛选栏中，
“神券”标签显示正常...</think>
<answer>
顶部筛选栏中，“密云区”和“通行距离”筛
选项的文字显示异常，存在溢出或截断
问题。
</answer>
```


三、技术演进与实践探索

3.5 智能UI异常检测

噪声照片



GPT4o

<think>

1. 检查页面顶部，发现右上角有一个绿色的“MRN”标签，明显遮挡了右上角的内容（如返回按钮或其他功能），属于UI遮挡问题。
2. 其他区域如顶部时间段、分类tab、商品卡片、价格、按钮等，未发现文字溢出、重叠、乱码、异常空白等问题。
3. 商品信息、价格、描述等内容均在各自模块内正常显示</think>

<answer>存在UI展示问题，右上角绿色“MRN”标签遮挡了页面内容，属于明显的UI遮挡问题。</answer>

SFT和GRPO

<think>从截图中可以看到，页面整体布局较为清晰，顶部的导航栏、时间轴、以及商品信息模块都正常显示。通过观察相邻元素，发现“2人炸鸡年糕套餐”模块中的价格下方的文字“已省93元，近180天最低价”部分存在异常。</think>
<answer>2人炸鸡年糕套餐”模块中的价格下方文字“已省93元，近180天最低价”存在文字重叠和溢出问题。</answer>

三、技术演进与实践探索

3.5 智能UI异常检测

专家模型对比GPT-4.1评测

实际场景评测区别于训练用合成数据

评测集数据分布

业务收集22个非简单的有问题场景，从正常场景中随机选取25个，共47个场景

UI问题普通截图 UI问题噪声照片 无问题截图



Prompt:

给你一个App截图，分析是否存在UI展示问题

===请遵循以下指令===

- 1.UI问题指UI重叠，遮挡，文字溢出组件边框，模块空白，乱码这些明显的，影响用户使用的问题，测试数据本身不是UI问题
- 2.观察页面模块布局，思考后给出判断结果<think>填入思考过程</think><answer>填入最终答案</answer>

召回率 - 有问题应检出，提升明显

专家模型 $15/22=68\%$ GPT-4.1 $4/22=18\%$

误报率 - 无问题不误报，略高一点

专家模型 $4/25=16\%$ GPT-4.1 $1/25=5\%$

三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：多模态模型微调 – 1.数据合成



经过人工筛选后生成290条数据

三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：多模态模型微调 – 2.模型训练

先模仿 - 有监督训练

环境信息

GPU - A100 x 1 基础模型 - Qwen2.5-VL 训练方式 - SFT Lora

训练过程

Supervised Fine-Tuning - SFT有监督训练是为了让基础模型先学会UI问题的基本模式，理解业务的关注点是什么。使用LoRA可以有效降低GPU需求，需多做实验观察调参的效果。我们通过训练前后的推理过程观察到，模型的注意力从观察背景颜色和布局位置，到已经有了接近人类QA的思考过程。

3.5 智能UI异常检测

无参考UI检测：多模态模型微调 – 2.模型训练

先模仿 - 有监督训练

SFT后的模型在一些场景上已经达到了预期效果，好像可以出师了，但是在部分没见过的场景上还是不够准确，为了增强鲁棒性进行下阶段的强化学习。

测试用例	基础模型-训练前	SFT训练后
	<think> 在分析这个App截图时，我主要关注了以下几个方面： ▽ 点击展开内容 </think><answer>存在以下UI问题： - 日期选择区域、数量选择区域、优惠信息区域和支付信息区域的背景色与整体页面颜色一致，可能会导致用户在这些区域的操作不够突出。 - 提交订单按钮的位置略显偏下，可能会影响用户的操作体验。 </answer>	<think>从截图中可以看到，页面整体布局较为清晰，元素之间的间距和对齐基本正常。通过观察相邻清晰的元素，发现“立减券”文字与其右侧的“免费开通”按钮之间存在重叠现象。这种重叠可能会遮挡部分文字内容，影响用户的阅读和操作。除此之外，页面其他部分未发现明显的UI展示问题。 </think><answer>“立减券”文字与右侧的“免费开通”按钮之间存在重叠，属于UI展示问题。 </answer>

三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：多模态模型微调 – 2.模型训练

自己摸索 – 强化学习

环境信息

GPU - A100 x 1 基础模型 - SFT训练后模型 训练方式 - GRPO Lora

强化学习

Policy Model - 训练过程中需要不断优化的目标模型

Reward Model - 用于对目标模型的回答进行打分，计算相对奖励和优势的依据，指导policy model的更新


三、技术演进与实践探索

3.5 智能UI异常检测

无参考UI检测：多模态模型微调 – 2.模型训练

自己摸索 – 强化学习

对于UI分析理解任务，Reward Function奖励函数的设计比较重要。例如，训练集中的正例都是短语“UI展示正常”，如果输出“UI展示没有问题”，奖励函数在计算两个语义相近的短语文本会给较高的分数，如果是长文本则不会很高，模型会认为高概率给正向短语判断得分多，实际上已经偏离了本质。所以，好的奖励函数做到公平公正，赏罚分明，这个过程人类训练师需观察日志不断调整策略。



三、技术演进与实践探索

3.6 智能化能力误报处理流程

误报事件收集

- 收集误报样本，记录case详情（时间、状态、模型版本、判定结果、原始数据等）。
- 建立误报事件知识库，便于后续追踪和分析。


误报数据回流与模型优化

- 将确认的误报样本及分析结果反馈至模型训练数据集或检索知识库。
- 迭代优化模型，提升准确率，减少误报率。

四、未来的趋势与挑战

现状：

AI赋能需求迭代与开发 -> 测试需求爆炸式增长



四、未来的趋势与挑战

未来：

AI测试AI，人工辅助review

测试设计	测试执行	结果分析
1.AI测试用例转换（基于已有链路信息 / checklist等生产前端自然语言测试用例） 2.测试用例AI生成（基于PRD、代码变更、历史缺陷等生成前端自然语言测试用例） 3.智能用例录入（基于历史trace、日志、请求等，自动录入前端执行case）	1.更准确、高效的自然语言UI驱动与校验 2.通用UI异常问题的垂类多模态大模型，用于检测通用UI问题 3.专注于UI功能驱动与检查的垂类多模态大模型 4.更智能且高效的终端遍历工具	1.页面回归Diff智能化归因 2.执行日志与截屏智能化分析 3.执行录屏智能化分析 4.页面覆盖率智能化评估 5.场景覆盖率智能化评估 6.历史前端缺陷智能化分析、归因

五、致谢

感谢聆听，欢迎交流！

六、附录

详细介绍:

1. 一句话让AI帮你做UI测试，多模态测试智能体AUITestAgent来了
2. 基于UI交互意图理解的异常检测方法
3. AutoConsis: UI内容一致性智能检测
4. <https://github.com/Meituan-Dianping/vision-ui>