

MTSC2025

中国互联网测试开发大会

TESTING SUMMIT CONFERENCE CHINA 2025

上海
站

质效革新·智领未来

2025/7/12 | 上海喜来登由由大酒店 主办方: TesterHome

MTSC2025 中国互联网测试开发大会 上海站
TESTING SUMMIT CONFERENCE CHINA 2025

TME AIGC生成音频质量保障建设

徐曼娜

质效革新·智领未来

主办方: TesterHome

目录

- 01 议题背景
- 02 AIGC音频评测标准体系构建
- 03 AI驱动的主客观评估引擎
- 04 规划与展望

01

议题背景


背景业务



QQ音乐 高品音质 银河音效 耳机适配



经典录唱 实时歌房/直播 音效合成



TME海量音频资源，核心玩法听歌/唱歌/直播，音频体验重中之重

传统玩法—>创新玩法

背景业务

真人演唱

声优演绎

厂牌制作

固参预设

TTA-歌声合成

TTS-语音合成

TTM-音乐合成


臻品音质



AI歌声



音色魔法师



AI角色互动



有声书



AI作歌




启明星



智能音效



臻品母带



AIGC音频评测面临的挑战

海量样本处理困境

有限的人工评测资源难以应付指数增长的生成音频，传统抽样检测机制存在覆盖度与时效性缺陷。

01

评估维度缺失风险

既有的客观评测工具在语音合成的自然度、音乐创作逻辑性等AI特有维度缺乏有效度量标准。


02

03

反馈机制脱节

单向质量检测无法构建“评估-优化”闭环，导致模型迭代周期与业务需求增长评测速率出现代际差。

AIGC音频质量保障体系构建思路



02

AIGC音频评测 标准体系构建

AIGC音频分类关键词

01

SVC

歌声转换
歌声生成
全音域覆盖
情感与表现力控制
多语言音库
呼吸声/辅音优化

02

TTS

文本生成语音
韵律/停顿拟人
多方言/多语种支持
高鲁棒性
实时交互

03

TTM

标签驱动生成音乐
旋律/和弦生成
多轨道编排
风格迁移
交互式编辑

04

臻品音质

大模型音效
臻品母带3.0
臻品全景声
高采样率
千歌千面

AIGC音频评测标准体系构建

构建完备的样本资源库

- 解决模型泛化能力不足
- 突破对抗样本防御盲区
- 消除数据偏见风险
- 应对生成技术代际差异

动态
样本
引擎

智能
评估
矩阵

- 打破单一指标局限性
- 统一行业评价基准
- 揭示隐性安全风险
- 驱动技术迭代方向

建立可解释的评测维度标准

分层测试体系设计


模块化架构构建多粒度测试集

核心问题挖掘策略

缺陷特征聚类+挑战性样本

智能物料生成技术

大模型加持提效



基于数据收集的样本

素材选段

固化量级

分类简单

Badcase累计



基于LLM的智能化测试样本


全音素设计

动态量级

层级分明

边界攻击

样本库构建



评测维度标准构建

AIGC音频 评测重点

基础质量

基础指标

解码错误

无效规则参
数

采样率/位深

音频类型错
误

...

质量指标

假无损

假Hires

音量

时长

...

音质指标

杂音

长空白音

爆音

...

内容质量

模型分类

Zero-shot

Few-shot

GPT-Sovits

syntaspeech

...

业务重点

音色克隆

语聊

音乐制作

...

特征解耦

音质

自然度

音乐性

相似度

...

评测标准重要依据

评测维度标准构建-通用标准

常见AIGC音频问题

电音

吞音

机械感

停顿不当

轻重音错位

信息错误

情感未表达

音节增多

抖动

平铺直叙

音调失衡

旋律突兀

音色不匹配





AIGC音频通用评测标准

MOS-音色相似度评估	MOS-音质评估	MOS-自然度评估	标注点
5分：对比音频人声音色完全一致，在口音，音调等方面也完全一致。	5分：全程音质很好，无任何瑕疵。	5分：全程自然度与真人演唱一致，演唱的情感和韵律起伏无任何瑕疵。	是否音色一致：包括但不限于句与句与中英文之间，是否存在音色突变，不像同一个人的现象。
4-5分：对比音频人声整体音色接近，能明显辨别出是属于同人发出的声音。	4-5分：整体音质较好，个别发音含轻微杂音/沙声/吞音，但不影响整体听感。	4-5分：整体自然度接近真人演唱，个别处演唱的情感和韵律起伏不恰当，但不影响整体听感。	是否有读错：包括但不限于中文多音字、英文读错、发音模糊，非正确读音等现象。
3-4分：对比音频人声整体音色有较小差异，能辨别出是同人发出的声音。	3-4分：整体音质良好，多处发音出现杂音/沙声/吞音，较影响听感。	3-4分：整体自然度良好，多处演唱的情感和韵律起伏不恰当，影响整体和谐。	是否有怪音：包括但不限于音质突然刺耳、沙哑或不和谐声音存在于句中等现象。
2-3分：对比音频人声整体音色有较大差异，较难辨别出是同人发出的声音。	2-3分：整体音质较差，声音不稳定，有金属感/杂音/沙声吞音，声音忽大忽小。	2-3分：整体自然度较差，超30%片段演唱的情感和韵律起伏与真人演唱差异大，较明显的机械感。	是否有停顿异常：包括但不限于非预期的词语中突然间隔、停顿过长、断句断词位置错误等现象。
1-2分：对比音频人声整体音色有很大差异，能明显辨别出是属于不同人发出的声音。	1-2分：整体音质很差，有较强的金属感/杂音/沙声/吞音，声音忽大忽小。	1-2分：整体自然度很差，超50%片段演唱的情感和韵律起伏与真人演唱差异大，明显不是真人演唱。	是否有韵律异常：包括但不限于音调过于平缓，无抑扬顿挫或突然拔高音调或激昂等现象。
0-1分：对比音频人声音色完全不一致，听不出对比音频人声有任何关联性。	0-1分：音质问题严重，无法听下去。	0-1分：自然度问题严重，完全不像真人演唱，机械感极重，无法听下去。	

评测维度标准构建-细化标准

TTS

TTM



03

AI驱动的主客观评估引擎

AI驱动的主客观引擎



AI驱动客观工具-音色相似度背景

业务背景



原声



效果一



效果二

质效革新·智领未来

痛点

1

主客观评测效率差异大

- 客观音质工具效率高，但无法衡量核心体验
- 主观评估反映真实体验，但回收耗时长

2

缺乏衡量相似度的评测工具

- 主观盲测群体不完全一致




急需建设覆盖语音+歌声场景的音色相似度
评测工具

主办方: TesterHome

AI驱动客观工具-音色相似度算法

- 创建主观标注数据集

- 语音+歌声的多类型的数据覆盖
- 关键预处理：VAD有效片段识别/空白帧分离




- 多情感数据集
- 多方言数据集
- ...

歌声分离音色：多语种、多流派、多场景

- 改进有参考质量评价算法

- 改进型ERes2NetV2架构
- 公开&私有数据集联合训练、finetune
- 多尺度特征融合
- 输入层优化
- 残差块级联策略



AI驱动客观工具-音色相似度算法

• 算法落地策略

- - 多语言 SDK：提供service demo 业务快速开发
- - Open API：GPU弹性平台部署，快速接入使用

业务数据集表现

模型	AI歌声 svc3.0	AI歌声 svc4.0	AI歌声 svc4.2
优化前模型相似度	0.49	0.48	0.59
优化后模型相似度	0.66	0.70	0.80
主观评测相似度	0.61	0.65	0.71

• 收益

- 贴合业务场景，准确性高，可拓展性强
- 质效提升，流程精简

应用广泛

接入场景：**3+**
累计数据：**3k+**

- AI歌声、AI试听、AI互动等场景
- 支持评测频次3k+，准确率超95%

效率提升

人力节省：**60%**
流程优化：**50%**

- 专项评测测试耗时3d->1d
- 算法准入，迭代频次下降50%

AI驱动客观工具-AI评价模型背景

业务背景



Prompt:
抒情, 安静, 温柔, pop

Verse:
告别温暖的梦 冷风吹散心痛
对未来的轻拥 希望别再仓促
一瞬间的美好 心中久久不老
即使未来多难 依然记得那桥



效果一



效果二

痛点

1

主观评测繁杂回收周期长

- 评测前期培训成本大
- 可靠的大规模评测耗时长
- 算法迭代支持度不佳

2

缺乏多维度衡量的评价系统

- 可解释性的多维度评价明确优化方向
- 现有工具在AIGC场景适用性&鲁棒性不佳

挑战：建设能反映多维度主观效果的音频评估工具，对AIGC类音频全面评估。

质效革新·智领未来

主办方: TesterHome

AI驱动客观工具-AI评价模型算法

• 创建主观数据集


- 去除原训练数据音效样本
- 增设真人演绎/AIGC类干声/音乐数据
- 时长优化(8.3->12)
- 众包标注可靠性保障

训练音频种类	详细类型
原部分训练数据	音乐/语音片段
录唱干声	优质/一般/劣质干声片段
录唱作品	优质/一般/劣质歌曲片段
音乐生成歌曲	音乐生成模型 (suno/udio/天工等) 作品
SVC(歌声转换)干声	ai歌声转换作品干声
TTS(语音转换)干声	ai语音/有声书作品干声

专业团队众包标注方式，独立人次30+/每条音频

• 优化无参考质量评价算法

- Transformer架构+WavLM音频编码器
- 首层卷积核调整+新增谐波增强模块
- 时序建模+多尺度窗口注意力
- **MLP决策：音频优质度+内容可用度+内容复杂度+音频愉悦度**



AI驱动客观工具-AI评价模型算法

业务数据集表现

模型	CE	PQ	PC	CU
AI试听v1	6.18	7.81	6.53	7.31
AI试听v2	6.26	7.81	6.54	7.31
主观评测	V2较优	差异不大	差异不大	差异不大

- 创建模型实现流程
 - 数据集构建、标注、清洗与预处理
 - 客观无参考音频质量评估架构设计：网络模型构成&模型训练
 - 评估方案建设、效果评估&调优

- 收益
 - 强力支撑算法及活动赛事多维度效果评价参考
 - 质效提升，归因明晰

专业度提升

接入场景：**5+**

累计数据：**1k+**

- AIGC算法、内容宣发赛事等专业质量保证

效率提升


人力节省：**40%**

精准分析**20%**

- 专项评测测试耗时3d->2d
- 对于算法优化点节省分析耗时20%

AI驱动客观工具- WER检测工具背景

业务背景



痛点

1

主观评测准确率不高，效率低

- 易混淆音素主观评测存在差异
- 错误处需要反复确认，效率低
- 错字错句展列的wer统计方式繁琐

2

缺乏衡量信息准确度的工具

- 对于发音、多音字、语种等模型处理能力没有工具进行快速对比，影响业务落地。

岭南的柠檬牛奶酿出了独特风味。

阿婆熬的藕粉含有薄荷的独特味道。



质效革新·智领未来

急需建设快速评价信息准确率的检测工具

Ps: WER为Word Error Rate
主办方: TesterHome

AI驱动客观工具- WER检测工具


• 开源模型调研

对比现有的成熟可靠的ASR模型作为检测核心——**Openai-whisper模型**

模型/工具	优点	缺点	适用场景
Whisper	✓ 多语言支持优秀 ✓ 预训练质量高，长音频处理稳定 ✓ 社区生态完善	✗ 模型体积大（如 large-v3 约 3GB） ✗ 纯中文场景需微调提升准度 ✗ 实时性一般（CPU 推理慢）	多语言混合、学术研究、非实时场景
FunASR	✓ 中文场景 SOTA 准度 ✓ 支持实时/离线识别 ✓ 工业级优化（高噪声鲁棒）	✗ 依赖较多组件（需安装 ModelScope） ✗ 多语言支持弱于 Whisper	企业级中文语音转写、实时交互
Paraformer	✓ 非自回归结构，推理速度快 ✓ 高噪声环境表现优秀 ✓ 长音频支持	✗ 需自行微调训练 ✗ 资源消耗中等（比 Whisper 低） ✗ 文档较少	客服录音分析、会议记录
WeNet	✓ 端到端设计，部署简单 ✓ 流式识别延迟低（~200ms） ✓ 支持嵌入式设备	✗ 纯中文需自训练 ✗ 长音频分段处理效果下降	实时语音交互、IoT 设备
Wav2Vec2 中文版	✓ 低资源场景表现好 ✓ 适合学术研究 ✓ 可迁移学习	✗ 需大量中文数据微调 ✗ 实时性差 ✗ 工业场景准度不足	学术实验、小规模定制化
HuBERT 中文微调	✓ 半监督学习，低资源有效 ✓ 语音表征学习能力强	✗ 训练复杂度高 ✗ 需搭配 ASR 框架 ✗ 非端到端设计	语音研究、定制化声学模型

• wer工具架构设计

三段式架构设计，识别模块的核心为whisper模型，检测模块贴合业务设计汉字-拼音双校验机制



AI驱动客观工具- WER检测工具

- 工具迭代优化

- 音乐领域专属名词维护
- 语气词识别兼容
- 数字/电话精准分化

业务数据集表现

数据集	精准率	召回率	F1 分数)
全场景数据	约80%+	约90%+	约80%+

- 收益

- 质量提升，高敏感反映语音清晰度，构建算法评测及业务内容准入标准
- 效率提升，大幅降低人力投入，异常快速聚类锁定优化方向

质量提升

接入业务：**4+**
累计数据：**5k+**

- 算法基座模型、声码器wer检测支持
- wer及发音清晰度量化工输出

效率提升

人力节省：**80%**
流程优化：**70%**

- 专项评测测试耗时3d->0.5d
- 业务生产内容wer标准准入

AI驱动客观工具- AI音质音效检测

算法缺陷挖掘

- 算法问题定性
- 明确检测方向


LLM+Alcoding

- 描述检测问题
- 需求代码直出

迭代检测闭环

- 多轮复检
- 监控入库

缺陷判定：特定频段衰减



方案+代码直出

以下是一个完整的Python脚本，用于检测歌曲在7kHz和11kHz是否存在频响衰减现象，包含频谱分析、衰减检测和可视化功能：

```
import librosa
import numpy as np
import matplotlib.pyplot as plt
from scipy.fft import fft, fftfreq
import pyloudnorm as pyln

def analyze_audio(audio_path, target_freqs=[7000, 11000], bandwidth=500, threshold_db=3):
    """
    检测音频在指定频率是否存在衰减
    参数:
        audio_path: 音频文件路径
        target_freqs: 目标频率列表(Hz)
        bandwidth: 检测带宽(Hz)
        threshold_db: 衰减判定阈值(dB)
    返回:
        dict: 各频率检测结果
        tuple: (频率数组, 频谱数据)
    """
```

Alcoding 调整补全

```
# 计算各频段平均值
target_power = np.sum(db_spectrum[target_mask])/len(db_spectrum[target_mask])
adjacent_power = (np.sum(db_spectrum[adjacent_low]) / len(db_spectrum[adjacent_low]) +
                  np.sum(db_spectrum[adjacent_high]) / len(db_spectrum[adjacent_high])) / 2

# 判断衰减
attenuation = adjacent_power - target_power
results[target_freq] = {
    'target_db': target_power,
    'adjacent_db': adjacent_power,
    'attenuation_db': attenuation,
    'has_attenuation': abs(attenuation) > threshold_db
}
```

算法问题检出

8kHz检测结果:

目标频段平均电平: -14.26 dB

相邻频段平均电平: -9.44 dB

衰减量: 4.82 dB

判断存在衰减: 是

11kHz检测结果:

目标频段平均电平: -28.65 dB

相邻频段平均电平: -22.01 dB

衰减量: 6.65 dB

判断存在衰减: 是

迭代验证闭环

8kHz检测结果:

目标频段平均电平: -2.22 dB

相邻频段平均电平: -2.28 dB

衰减量: -0.06 dB

判断存在衰减: 否

11kHz检测结果:

目标频段平均电平: -7.02 dB

相邻频段平均电平: -7.02 dB

衰减量: -0.01 dB

判断存在衰减: 否


主观评测实践-天秤评测平台

支持功能

主观评测：质量评测、AIGC标注评测、自定义任务

客观指标：音视频指标计算

结果分析：图表展示、聚类分析




支持类型

视频、音频、文本、图片、AI对话

整体优势

多种平台支持
多种展示模式
多种打分机制
自动数据分析



单/双音视频评测



Mos/Dmos/JND

主办方: TesterHome

AI驱动的主客观评估引擎-实践案例

- AI歌声SVC效果提升

- 竞品对比分析
- 算法优化

- 流量分发&生态建设

- 优质作品推荐分发
- 导唱库生态建设



AI驱动的主客观评估引擎-落地业务

基于AI驱动的主客观评估引擎


- **入库监控**: 基础音质检测
- **测试评估**: 样本库+自动化处理+相似度/评价系统等客观工具支持+天秤主观盲测平台

• 工具接入情况

- **支持业务**: QQ音乐、全民K歌及酷狗等10+音频业务
- **应用范围**: SVC/SVS/TTS相似度优化, TTM好听度优化、伴奏&导唱库质量提升专项、音质优化算法
- **调用次数**: SDK/API接入10w+

• 协同合作

- TME&腾讯Oteam分享开源



AI驱动的主客观评估引擎

- 节省测试人力
- 增加覆盖范围

- 客观评估准确性高
- 优化目标明确
- 指标可量化





- 辅助产品制定策略
- 提升用户体验

- 协同合作
- 行业交流

04

未来规划&展望

总结-三维一体建设音频评测体系



专项内容突破

标准建设

测试标准&方法完善：协同共建、沉淀积累
样本库充盈：利用LLM技术优化

工具建设

客观工具建设：自研&外部引入
主观平台完善：AIGC特性适配
质检监控：大盘统计、入库监控

专项突破

音质提升专项、韵律提升专项、对外合作

评测方案
标准完善

评估工具建设

01

样本生成工厂



定向生成包含多语种方言、多情感、音素冲突、韵律断裂等缺陷的挑战性样本，确保评估体系的前瞻性与压力测试完备性。

02



客观评价引擎

持续深度融合传统声学指标与深度学习表征，构建更为贴合场景的客观评估模型，提高质量效率。

03




主观评测平台



持续优化天秤评测平台的工具使用体验，增设ABX多版本同页面对比、AIGC音频prompt匹配度等多维度评测支持。

04



工具平台化

通过微服务架构整合离散工具链，构建「生成-评测-优化」闭环工作流。

谢谢
THANKS